

# 面向强 AI 自动标注的 Canonical Semantic Decision Entity、Semantic Obligation Hypergraph 与 Operational Complexity 向量规范

## 执行摘要

本报告给出一套可以直接进入试水实验和后续论文方法部分的 **v1.0 规范**。核心结论首先需要说清楚：

**“canonical semantic decision entity” 与 “semantic obligation hypergraph” 并不是当前 NL→OR 文献已经标准化的现成术语。它们更适合作为我们在既有研究基础上提出的新 operationalization。**

现有工作提供了四块非常重要但彼此尚未统一的基础。NL4Opt 把自然语言优化建模拆成“识别 optimization entities”和“生成 machine-interpretable formulation/meaning representation”；MIPLIB-NL 从工业 MILP 中恢复 indexed variable groups、repeated constraint structures，并明确区分 problem description、data、`model.md` 和 solver implementation；IR2Solve 又证明了一个 schema-constrained intermediate representation 可以把“语义建模”与“确定性 IR→solver compilation”分开；ORAgentBench 则明确把 **constraint coupling** 放进六维 difficulty rubric，并强调难度不能被 problem size 单独代表。<sup>1</sup>

另一方面，CSP 理论已经有非常成熟的“变量—constraint scope—hypergraph—primal graph—treewidth”结构理论：constraint 的 scope 是它所涉及的变量集合；约束的 incidence hypergraph 会显著影响 CSP 的计算复杂性；binary CSP 与 primal-graph treewidth 有非常紧密的关系，而高元 hyperedge 情况则需要 fractional hypertree width、submodular width 等更一般的 hypergraph width。<sup>2</sup> **但我们的 semantic family-level hypergraph 不是 scalar CSP hypergraph，因此绝不能直接宣称 semantic treewidth 小就意味着 OR 问题 polynomial-time solvable。**CSP 理论在本研究中是结构理论来源，而不是我们 complexity 指标已有计算复杂性定理的依据。

基于这些文献和我们此前确定的研究目标，我建议固定下面的双层结构：

$$\text{Operational specification} \longrightarrow H_S \longrightarrow \mathbf{OC}_{\text{HG}}^{(S)}$$

其中  $H_S$  是 **problem-intrinsic semantic obligation hypergraph**；它只依赖自然语言、数据语义和 business rules，不依赖具体 MILP/CP/solver encoding。另一方面，

$$\text{chosen mathematical formulation} \longrightarrow H_A \longrightarrow \mathbf{OC}_{\text{HG}}^{(A)}$$

其中  $H_A$  是 formulation-dependent algebraic hypergraph，用于测量 representation inflation、auxiliary-variable coupling、linearization 等，而**不等于** **intrinsic operational complexity**。

本报告建议将 semantic 层的基本单位严格定义为：

CSDE = 一个 endogenous、decision-relevant、具有稳定业务语义和 index signature 的 quantity/relation fam

例如

`production(product,period), inventory(product,period), customer_assignment(customer,facil`

parameter、set、成本、容量、需求等 exogenous quantities 不作为 node；纯 Big- $M$  helper、MTZ order variable、linearization auxiliary、solver slack 等没有独立业务语义的变量也不作为 semantic node。

Semantic obligation 则定义为一个：

minimal、independently falsifiable、与 feasible region 有关的业务/物理/逻辑要求

因此 objective 默认不作为 semantic obligation；objective 是在 feasible set 上排序，而 constraint 决定 feasible set。这与我们研究“为什么 LLM 更容易漏掉/错误表达 feasibility conditions”高度一致。IR2Solve 最新工作尤其提醒，**objective value 一致并不能证明 feasible region 一致**；一个模型可以得到相同 optimum，却遗漏或增加 constraints。 <sup>3</sup>

这里有一个相当重要的方法升级：**单一 entity-primal graph 不足够**。当一个 LP 只有 `production(product)` 一个 variable family，但有 labor、material、market、emission 四类 constraints 时，entity-primal graph 只有一个 node，treewidth、cycle、spectral interaction 全为零；但显然这些 constraints 共享同一 decision family。为此，本规范从一个 semantic hypergraph 同时构造：

$$G_V = \text{entity-primal graph}, \quad G_O = \text{obligation-intersection graph}.$$

前者测量“不同 decision concepts 如何相互缠绕”，后者测量“不同 business rules 如何争用同一批 decision concepts”。这是目前我认为比我们此前 v0.1 更稳健的设计。

因此 semantic operational-structure vector 建议暂定为：

$$\text{OC}_{\text{HG}}^{(S)} = [\mathbf{S}; \mathbf{C}_{\text{local}}; \mathbf{C}_V; \mathbf{C}_O]$$

其中 size/burden control:

$$\mathbf{S} = (n, m, L, \bar{a}),$$

local overlap:

$$\mathbf{C}_{\text{local}} = (D_I, D_{\cap}, J_+),$$

entity-interaction:

$$\mathbf{C}_V = (C_{\text{spec}}^V, C_{\text{tw}}^V, C_{\text{hub}}^V, C_{\text{cyc}}^V, C_{\text{LCC}}^V),$$

rule-interaction 的 MVP 核心先保留：

$$\mathbf{C}_O = (C_{\text{spec}}^O, C_{\text{tw}}^O),$$

同时记录 obligation-side hubness、cycle rank、LCC 作为 diagnostics。暂时不聚合成一个 scalar。

更重要的是，这组指标不是声称“已被理论证明的 operational complexity”；它是一个**可复现、可证伪的 candidate structural difficulty measure**。真正的论文贡献要通过后续实验回答：

$$\mathbf{OC}_{\text{HG}}^{(S)} \xrightarrow{?} P(\text{constraint-formulation error}) \xrightarrow{?} P(\text{infeasible final solution})$$

OPT-Engine 已发现 solver-integrated reasoning 下 constraint formulation 是主要瓶颈；ORAgentBench 的 failure analysis 也观察到 missed operational rules、brittle formulations 和 weak feasible-solution construction，并明确把 constraint coupling 作为 construction-time difficulty dimension。<sup>4</sup> 我们的论文机会就在于：把“constraint coupling”从 qualitative rubric 变成严格、可自动标注、可计算、可验证的 problem-level structural variable。

## 理论基础与规范化定义

### 从现有 NL→OR 表示到我们的 semantic layer

NL4Opt 给出的最早清晰 pipeline 是：

stakeholder description → decision variables/objective/constraints → algebraic formulation.

它把第一项任务定义为 optimization-problem entity recognition，把第二项定义为 formulation generation / semantic parsing，也就是从文本提取 machine-interpretable meaning representation。<sup>5</sup> 但是 NL4Opt 中的 entity category 包含 variable、parameter、constraint limit、objective direction 等文本 span 类型；它还不是我们要的“跨不同 mathematical encodings 保持不变的 canonical decision concept”。

MIPLIB-NL 更接近我们需要的 family-level 思想。它不是把原始 MPS 的百万级 scalar rows 直接转成文本，而是先执行 **structural abstraction**，恢复 compact reusable structures，再生成自然语言；官方数据格式又明确提供 sets、parameters、decision variables、constraints、objective 的 model.md。其 benchmark 有 223 个经过 reconstruction/validation 的实例，且模型规模可达到数十万变量和百万级 constraints，这使“不能把 scalar variable/row 当 semantic node/edge”成为非常现实的问题。<sup>6</sup> MIPLIB-NL 的结构分析还明确区分 single-loop、nested-loop、coupled-loop、network-indexed、pairwise 等约束结构，并列出了 flow conservation、capacity、Big- $M$  implication、exactly-one 等 constraint patterns。<sup>7</sup>

IR2Solve 则进一步给出了：

$$d \rightarrow m \rightarrow c$$

的思想：自然语言 description 先映射到 structured ModelIR，再由 deterministic verifier/compiler 转为 solver representation。它的 ModelIR 明确保存 sets、parameters、variables、objective、constraints。

<sup>8</sup> 这对我们最重要的启示不是照搬 ModelIR，而是确认：

**semantic extraction 和 solver implementation 可以被人为分离。**

LEAN-LLM-OPT 也把 problem description、associated/reference datasets 与后续 optimization modeling workflow 分开，其公开 repository 包含 101 个 Large-scale-OR benchmarks 和 Ref-Data 文件。<sup>9</sup>

所以，本研究提出的 CSDE/SOH 可以看成对这些工作的进一步 abstraction：

$$\text{NL/data} \rightarrow \underbrace{\text{problem-intrinsic semantic representation}}_{\text{我们}} \rightarrow \underbrace{\text{formulation IR/model}}_{\text{NL4Opt/MIPLIB-NL/IR2Solve}} \rightarrow \text{solver code.}$$

### Canonical Semantic Decision Entity

给定完整 operational instance：

$$P = (T, \Theta, \mathcal{R}, \mathcal{O}),$$

其中:

- $T$ : 自然语言说明;
- $\Theta$ : exogenous sets、parameters、data;
- $\mathcal{R}$ : business/physical/logical rules;
- $\mathcal{O}$ : objective specification.

定义一个 **Canonical Semantic Decision Entity, CSDE**

$$e = (r, \mathcal{I}, \mathcal{D}, \tau, u)$$

为一个 endogenous、decision-relevant 的 semantic quantity 或 relation family, 其中:

$r$  = semantic role/predicate,

$\mathcal{I} = (I_1, \dots, I_k)$  = canonical index signature,

$\mathcal{D}$  = semantic value kind,

$\tau$  = temporal/state semantics,  $u$  = unit/quantity semantics.

它表示一个 family:

$$z_e : \mathcal{I}_e \rightarrow \mathcal{D}_e$$

或者对于 relation 型决策:

$$z_e \subseteq I_1 \times \dots \times I_k.$$

例如:

$$e_1 = \text{production}(\text{product}, \text{period})$$

表示“每产品每期生产量”这一 endogenous concept, 而不是  $100 \times 365$  个 scalar nodes.

### Canonical 的严格含义

两个文本 mentions  $a, b$  合并成一个 CSDE, 当且仅当在忽略自然语言别名和 index 符号重命名后, 它们表达的是同一个 endogenous operational relation:

$$a \sim b \iff K(a) = K(b),$$

其中 canonical key 可以实现为:

$$K(e) = (\text{semantic role, argument roles, time grain, quantity/relation kind}).$$

所以:

plant production in month t

和

monthly amount manufactured at factory

若都指 product×month 上的生产数量，可以 canonicalize 为：

production(product, period)

但：

shipment(origin, destination)

和

shipment(origin, destination, period)

不能仅因为词义接近就合并，因为 index signature 不同。

同样：

facility\_open(facility)

与

customer\_assignment(customer, facility)

绝不能因为某一种 MILP encoding 能从一个推导另一个而合并；它们是不同的 business relations。

## Endogenous state 是否算 decision entity

这一点必须特别规范，否则 inventory、completion time、vehicle load 会成为巨大 annotation noise。

本文规定：

只要一个 endogenous state 在业务语义中具有独立身份，并且业务规则或目标直接针对它陈述要求，它可以成为 CSDE，即使在某种 mathematical formulation 中它是 derived variable。

因此：

inventory(product, period)

通常是 CSDE，因为库存水平本身是一个 operational state，库存平衡、warehouse capacity、safety stock 等规则直接作用于它。

但 CVRP 中为了 MTZ subtour elimination 引入的：

$$u_i$$

通常**不是** CSDE，因为 “MTZ ordering number” 不是业务问题本身要求做出的 operational decision。

Vehicle-load variable则取决于语义：

如果原题只是：

每辆车总配送量不得超过容量。

某种 formulation 为了方便引入  $load_{ki}$ ，它是 algebraic auxiliary。

若题目本身描述：

车辆在每次 pickup/delivery 后的车载量随路径发生变化，并且任一点都不不得超过容量，

那么：

$$\text{onboard\_load}(\text{vehicle}, \text{node})$$

可以成为有独立 operational semantics 的 endogenous state。

**判断标准永远是 problem semantics，而不是 solver code 是否声明了变量。**

## Semantic Obligation

定义 semantic obligation  $o$  为一个 family-level predicate：

$$\phi_o(z_{\sigma(o)}, \Theta) = \text{True},$$

其中：

$$\sigma(o) \subseteq V_S$$

是满足/检查该 obligation 所需要读取的 endogenous semantic entity families。

一个 obligation 必须同时满足：

### Feasibility-relevant:

它规定哪些 operational decisions 可接受，即参与定义 intended feasible set。

### Independently falsifiable:

可以概念上问：

“一个 candidate decision 是否违反这一条？”

例如：

每个 customer 必须且仅能被分配一次。

可以独立违反，因此是一条 obligation。

### Family-minimal:

按业务 rule template 而不是 scalar index 拆分。

$$\sum_f x_{cf} = 1, \quad \forall c$$

是一个 `assign_each_customer_once` obligation family，而不是  $|C|$  个 obligations。

但：

每个 customer 必须分配一次，并且只能分配给已开启的 facility。

应拆成：

$$o_1 = \text{assign exactly once}$$

和

$$o_2 = \text{assignment requires open facility,}$$

因为两者可以独立违反。

这与 CSP 中 constraint scope 的基本思想一致：一个 constraint 的 scope 是受到该 constraint 限制的变量集合。<sup>10</sup> 我们的区别是把 scalar CSP variables 替换为 canonical semantic **families**，因此这是 CSP hypergraph 的 semantic abstraction，而不是普通 CSP hypergraph。

## Semantic Obligation Hypergraph

普通 hypergraph:

$$H = (V, E)$$

允许一条 edge 同时连接两个以上 vertices，因此比 ordinary graph 更自然地表达：

$$\text{inventory balance} : \{\text{production, inventory, shipment}\}.$$

但我们需要比普通 simple hypergraph 更强的结构：

$$H_S = (V_S, O_S, \sigma, \rho)$$

其中：

$$V_S = \{e_1, \dots, e_n\}$$

为 CSDE families;

$$O_S = \{o_1, \dots, o_m\}$$

是 **obligation multiset**;

$$\sigma : O_S \rightarrow 2^{V_S}$$

给出 hyperedge support;

$$\rho(o)$$

保存 rule 的 semantic metadata。

之所以必须是 **multi-hypergraph**，是因为以下两条不同 business rules:

$$\sum_p a_p x_p \leq L$$

labor capacity

和

$$\sum_p b_p x_p \leq M$$

material capacity

都可能具有相同 support:

$$\sigma(o_{\text{labor}}) = \sigma(o_{\text{material}}) = \{\text{production}\},$$

但它们不能被折叠成同一个 obligation。

所以:

$$o_i / o_j =$$

完全可以满足:

$$\sigma(o_i) = \sigma(o_j).$$

这件事后来会成为我们使用 **obligation-intersection graph** 的重要理由。

## Hyperedge 还必须保存 role/index 信息

单独保存:

"support\_entity\_ids": ["route\_arc"]

还不够，因为下面的 flow conservation:

$$\sum_j x_{kji} = \sum_j x_{kij}$$

只涉及一个 variable family `route_arc(vehicle,from,to)`，但它显然把很多 **scalar decisions 跨 index 耦合起来**。

因此 obligation 还要保存：

```
incidence_slots
```

例如：

```
[
  {
    "entity_id": "route_arc",
    "role": "inbound_flow",
    "index_binding": {"to": "i"},
    "aggregation_axes": ["from"]
  },
  {
    "entity_id": "route_arc",
    "role": "outbound_flow",
    "index_binding": {"from": "i"},
    "aggregation_axes": ["to"]
  }
]
```

并标记：

```
"cross_instance": true
```

这样我们可以坚持 family-level graph，而不把关键的 intra-family coupling 信息完全丢掉。

第一版主 metric 仍根据 unique support：

$$\sigma(o)$$

计算，以保证自动化稳定性；`incidence_slots` 和 `cross_instance` 留作后续 refined coupling 指标。

## Semantic 与 algebraic layer 的边界

定义 algebraic layer：

$$H_A = (V_A, C_A, \sigma_A).$$

一个 **variable family** 是同一个数学 declaration/template 产生的一组 scalar variables：

$$X_j = \{x_\alpha : \alpha \in \mathcal{I}_j\}.$$

例如：

$$x_{ijt} \quad \forall (i, j, t) \in I \times J \times T$$

是一个 variable family。

一个 **constraint family** 是同一个 quantified algebraic template 的实例集合：

$$C_k = \{g_\beta(x) \leq 0 : \beta \in \mathcal{J}_k\}.$$

例如：

$$\sum_j x_{ijt} \leq C_{it} \quad \forall i, t$$

是一个 constraint family，而不是  $|I||T|$  条 family-level edges。

MIPLIB-NL 恰恰是在从 flattened solver formulation 恢复这类重复结构，官方 `model.md` 也按 sets、parameters、variables、constraints 和 objective 提供模型。 <sup>11</sup>

semantic 与 algebraic 之间可以定义 mapping：

$$\pi_V : V_A \rightarrow 2^{V_s} \cup \{\perp\},$$

以及：

$$\pi_C : C_A \rightarrow 2^{O_s} \cup \{\perp\}.$$

$\perp$  表示：

“这个 algebraic element 没有独立 semantic counterpart。”

例如：

$$u_i^{MTZ} \mapsto \perp.$$

这正是 representation stress-test 所需的结构。

### 哪些元素计入，哪些不计入

| 元素                                        | Semantic node | Semantic obligation | Algebraic layer | 规则                             |
|-------------------------------------------|---------------|---------------------|-----------------|--------------------------------|
| 实际生产量、shipment、assignment、route choice    | 是             | —                   | 是               | endogenous operational concept |
| inventory/completion 等真实 endogenous state | 通常是           | —                   | 是               | 前提是业务语义直接使用                    |

| 元素                                  | Semantic node    | Semantic obligation | Algebraic layer  | 规则                                    |
|-------------------------------------|------------------|---------------------|------------------|---------------------------------------|
| demand、capacity、cost、distance       | 否                | 否                   | parameter        | exogenous                             |
| index set / customer list / periods | 否                | 否                   | set              | 不属于 decision                          |
| objective                           | 否                | <b>核心图中否</b>        | 单独保存             | objective 排序 feasible decisions       |
| capacity rule                       | —                | 是                   | constraint       | substantive feasibility condition     |
| time window                         | —                | 是                   | constraint/bound | substantive business rule             |
| “最多工作 8 小时”                         | —                | 是                   | 即使实现为 bound 也算   | 语义决定，不按代码语法决定                         |
| $x \geq 0$ 的一般 nonnegativity        | entity attribute | 否                   | domain/bound     | 通常是 representation/domain declaration |
| binary/integer declaration          | entity attribute | 否                   | domain           | 不作为 coupling edge                     |
| Big- $M$ auxiliary                  | 否                | 否                   | 是                | implementation-only                   |
| MTZ order variable                  | 通常否              | 否                   | 是                | routing formulation artifact          |
| slack variable                      | 否                | 否                   | 是                | implementation-only                   |
| epigraph/helper variable            | 通常否              | 否                   | 是                | 除非问题本身赋予业务意义                          |
| solver cut / symmetry breaking      | 否                | 否                   | 是                | solver/formulation strengthening      |
| aggregation variable                | 视语义              | 视语义                 | 是                | 有独立业务意义才进入 semantic                   |
| 同一 business rule 的不同 scalar rows    | —                | 一个 family edge      | 多 scalar rows    | family-level collapse                 |
| 两个不同 rules、相同 support               | —                | <b>两个 edges</b>     | 两个 families      | multi-hypergraph 保留                   |

MIPLIB-NL 本身将 aggregation definitions、logical implication、domain/integrality 等作为不同 algebraic structural patterns，这也说明“solver model 中出现的结构”与“问题自身的 semantic obligations”不能直接画等号。<sup>7</sup>

objective 虽不进入 feasibility-coupling core，但不能从 annotation schema 中删除。应保存：

$$O = (\text{sense}, \text{semantic objective}, V_{\text{obj}})$$

以便未来单独定义 objective semantic complexity。OPT-Engine 当前实验集中在 LP/MIP exact-solution setting，并发现 constraint formulation 是 solver-integrated reasoning 的主要 bottleneck；它同时承认 nonlinear、stochastic、dynamic、heuristic/time-budget settings 需要进一步扩展。<sup>12</sup> 因而现在把 feasibility coupling 和 computational difficulty 分开，是一个有清晰研究边界的做法，而不是声称 objective 永远不重要。

### 三种基本拓扑为什么必须区分


考虑四个 entities：

$$V = \{a, b, c, d\}.$$

**Star:**

$$O = \{\{a, b\}, \{a, c\}, \{a, d\}\}.$$

其 entity graph 是：



这里：

$$\text{tw} = 1, \quad C_{\text{hub}} = 1, \quad \mu = 0.$$

它是 **hub-dominated coupling**。

**Cycle:**

$$O = \{\{a, b\}, \{b, c\}, \{c, d\}, \{d, a\}\}.$$

则：

$$\text{tw}(C_4) = 2, \quad C_{\text{hub}} = 0, \quad \mu = 1.$$

这是 **cyclic dependency**，不是 hub structure。

**Clique-like:**

若所有 pair 都有 obligation：

$$G_V = K_4,$$

则：

$$\text{tw}(K_4) = 3, \quad C_{\text{hub}} = 0, \quad \mu = 3.$$

这是 dense global entanglement。

因此：

coupling 不是单一“多/少”标量，而至少有 density、width、hub、cycle 等不同形态。

这与 CSP literature 使用 treewidth / hypergraph width 描述 constraint interaction structure 的传统是一致的；但 Marx 的结果也明确指出，约束可以包含任意多个变量时，仅用 primal treewidth 并不足以涵盖 hypergraph tractability。<sup>13</sup> 所以我们使用 vector-first，而不是试图从第一天构造一个“万能 complexity scalar”。

## 强 AI 标注协议与 JSON 规范

### 标注原则

第一版 semantic annotation 必须坚持一个非常重要的实验隔离原则：

Primary semantic annotator 不看 gold model.md / solve.py。

否则所谓 problem-intrinsic semantic graph 会受到 gold mathematical formulation 的 representation leakage。

gold model.md 只在第二条独立 pipeline 中构造  $H_A$ ，随后用于 semantic-algebraic alignment / QC。MIPLIB-NL 天然适合这种实验，因为每个 instance 分开提供 natural-language description、raw data、model.md 和 reference solve.py。<sup>14</sup>

IR2Solve 的 schema-constrained ModelIR 和 deterministic compiler 已表明强模型在结构化 schema 下输出中间表示是现实可行的技术路线。<sup>8</sup> 我们的 prompt 应比一般“请提取变量与约束”更严格，因为这里不是让 AI 自己选择 formulation，而是让它**停止在 semantic layer**。

### 可直接使用的 System Prompt 模板

#### SYSTEM ROLE

You are a semantic annotation engine for operations-research problem specifications.

Your task is NOT to solve the optimization problem, NOT to choose a solver, NOT to generate mathematical programming code, and NOT to reproduce a particular MILP/CP formulation.

Your task is to recover a problem-intrinsic semantic representation consisting of:

1. exogenous sets and parameters;
2. canonical semantic decision entities (CSDEs);
3. the objective semantics, stored separately;
4. semantic feasibility obligations;
5. a semantic-obligation multi-hypergraph.

A CSDE is an endogenous, decision-relevant operational quantity or relation family with a stable real-world semantic role and index signature.

A semantic obligation is one minimal, independently falsifiable business,

physical, logical, or operational feasibility requirement.

#### CRITICAL RULES

##### A. Work at FAMILY LEVEL.

Do not create one entity per customer/product/time/index value.

Example:

production(product, period)

is ONE entity family.

B. Parameters, sets, capacities, demands, costs, distances and externally given data are NOT decision entities.

C. Do NOT introduce algebraic auxiliary entities merely because a standard formulation might use them.

Examples normally excluded from the semantic layer:

Big-M helper variables

MTZ ordering variables

artificial slack variables

linearization auxiliaries

epigraph variables

symmetry-breaking variables

solver cuts.

D. Endogenous operational states MAY be CSDEs if the problem itself gives them independent semantic meaning.

Examples:

inventory(product, period)

completion\_time(job)

but not a helper variable that exists only in one solver formulation.

E. The objective is NOT a feasibility hyperedge.

Store objective semantics and objective entity scope separately.

F. Generic variable-domain declarations such as non-negativity, integrality or binary encoding are entity metadata and NOT semantic-obligation hyperedges.

However, substantive operational limits such as "a worker may work at most 8 hours", "inventory cannot exceed warehouse capacity", or "delivery must occur within its time window" ARE semantic obligations, even if a solver implementation uses a variable bound rather than an explicit constraint row.

G. Split a sentence into multiple obligations whenever the requirements are independently falsifiable.

Example:

"Every customer is assigned exactly once and only to an open facility"

must become:

assign\_each\_customer\_once

assignment\_requires\_open\_facility

H. Preserve distinct obligations even when they have identical entity support.

Do not merge labor capacity and material capacity merely because both constrain

production(product).

I. For every obligation provide exact source grounding, quantification/index information, parameter references, and incidence roles.

J. If one obligation aggregates or relates multiple scalar instances of the same entity family, mark:

cross\_instance = true

and describe the relevant aggregation/index roles in incidence\_slots.

K. Do not invent unstated parameters, sets, rules or operational assumptions. If required information is absent, put it in unresolved\_items.

L. Canonicalization:

Merge textual aliases only when they denote the same endogenous operational relation with the same argument roles and temporal granularity.

Do not merge entities merely because one can be mathematically derived from another.

M. Return JSON only, conforming exactly to the supplied schema.

## User input格式

当前 pilot 假定“参数及其业务含义都能提供给 annotator”。建议统一为：

```
{
  "instance_id": "example_001",
  "annotation_mode": "semantic",
  "problem_text": "完整自然语言题面……",
  "sets": [
    {
      "name": "customers",
      "description": "customers that must be served",
      "values": ["c1", "c2", "c3"]
    }
  ],
  "parameter_tables_inline": [
    {
      "name": "demand",
      "indices": ["customer"],
      "unit": "units",
      "values": {
        "c1": 4,
        "c2": 5,
        "c3": 3
      }
    }
  ],
  "external_file_manifest": [],
```

```
"notes": "All parameter semantics required for annotation are supplied."
}
```

对于 MIPLIB-NL 和 ORAgentBench 一类 multi-file benchmark, 未来可以使用 `external_file_manifest`。ORAgentBench 的 task packet 本来就包含 natural-language brief、data/configuration artifacts, 并要求所有求解所需信息都包含在给定 materials 中; MIPLIB-NL 则显式把 data files 的 path、schema、description 与 `model.md` 分离。<sup>15</sup>

外部文件模式应当遵循:

```
{
  "external_file_manifest": [
    {
      "file_id": "demand_csv",
      "semantic_role": "customer demand table",
      "schema": ["customer_id", "demand"],
      "content_available_to_annotator": true
    }
  ]
}
```

如果文件不可访问, AI **不得推断文件内容**:

```
{
  "unresolved_items": [
    {
      "type": "missing_data",
      "description": "Customer-group membership required by rule R7 is not available."
    }
  ]
}
```

对于 family-level topology, 很多情况下数值本身并不改变 graph; 例如容量从 100 改成 120, constraint support 不变。但如果 data 决定某个 subset、compatibility relation 或 allowed arcs, 那么相关 schema/subset 内容必须提供, 否则 semantic structure 可能改变。

## 推荐 JSON Schema

下面是能够直接实现 validator 的简化但完整 v1 结构:

```
{
  "$schema": "https://json-schema.org/draft/2020-12/schema",
  "title": "SemanticObligationHypergraph-v1",
  "type": "object",
  "required": [
    "schema_version",
    "instance_id",
  ]
}
```

```

"layer",
"sets",
"parameters",
"entities",
"objective",
"obligations",
"unresolved_items"
],
"properties": {
  "schema_version": {
    "const": "SOH-1.0"
  },
  "instance_id": {
    "type": "string"
  },
  "layer": {
    "const": "semantic"
  },
  "sets": {
    "type": "array",
    "items": {
      "type": "object",
      "required": ["id", "description"],
      "properties": {
        "id": {"type": "string"},
        "description": {"type": "string"},
        "source_spans": {
          "type": "array",
          "items": {"type": "string"}
        }
      }
    }
  },
  "parameters": {
    "type": "array",
    "items": {
      "type": "object",
      "required": ["id", "indices", "description"],
      "properties": {
        "id": {"type": "string"},
        "indices": {
          "type": "array",
          "items": {"type": "string"}
        },
        "description": {"type": "string"},
        "unit": {"type": ["string", "null"]},
        "data_ref": {"type": ["string", "null"]},
        "source_spans": {
          "type": "array",
          "items": {"type": "string"}
        }
      }
    }
  }
}

```

```

    }
  }
},
"entities": {
  "type": "array",
  "items": {
    "type": "object",
    "required": [
      "id",
      "canonical_name",
      "semantic_type",
      "indices",
      "description",
      "endogenous",
      "source_status"
    ],
    "properties": {
      "id": {"type": "string"},
      "canonical_name": {
        "type": "string",
        "pattern": "^[a-z][a-z0-9_]*$"
      },
      "semantic_type": {
        "enum": [
          "quantity",
          "assignment",
          "activation",
          "flow",
          "route",
          "sequence",
          "time",
          "state",
          "allocation",
          "other"
        ]
      },
      "indices": {
        "type": "array",
        "items": {
          "type": "object",
          "required": ["role", "set_id"],
          "properties": {
            "role": {"type": "string"},
            "set_id": {"type": "string"}
          }
        }
      },
      "description": {"type": "string"},
      "value_semantics": {"type": ["string", "null"]},
      "unit": {"type": ["string", "null"]},
      "endogenous": {"const": true},

```

```

"source_status": {
  "enum": [
    "explicit",
    "implicit_required"
  ],
},
"source_spans": {
  "type": "array",
  "items": {"type": "string"}
},
"confidence": {
  "type": "number",
  "minimum": 0,
  "maximum": 1
}
}
},
"objective": {
  "type": "object",
  "required": [
    "sense",
    "description",
    "entity_scope",
    "excluded_from_feasibility_hypergraph"
  ],
},
"properties": {
  "sense": {
    "enum": ["minimize", "maximize", "satisfy", "unknown"]
  },
  "description": {"type": "string"},
  "entity_scope": {
    "type": "array",
    "items": {"type": "string"}
  },
},
"parameter_refs": {
  "type": "array",
  "items": {"type": "string"}
},
"excluded_from_feasibility_hypergraph": {
  "const": true
},
"source_spans": {
  "type": "array",
  "items": {"type": "string"}
}
},
"obligations": {
  "type": "array",
  "items": {

```

```

"type": "object",
"required": [
  "id",
  "canonical_name",
  "obligation_type",
  "normalized_semantics",
  "support_entity_ids",
  "incidence_slots",
  "parameter_refs",
  "cross_instance",
  "coupling_active",
  "source_spans"
],
"properties": {
  "id": {"type": "string"},
  "canonical_name": {"type": "string"},
  "obligation_type": {
    "enum": [
      "capacity",
      "balance",
      "conservation",
      "coverage",
      "assignment",
      "linking",
      "precedence",
      "non_overlap",
      "time_window",
      "logical_implication",
      "service_requirement",
      "resource_limit",
      "policy",
      "other"
    ]
  },
  "normalized_semantics": {"type": "string"},
  "support_entity_ids": {
    "type": "array",
    "uniqueItems": true,
    "items": {"type": "string"}
  },
  "incidence_slots": {
    "type": "array",
    "items": {
      "type": "object",
      "required": [
        "entity_id",
        "role",
        "aggregation_axes"
      ],
      "properties": {
        "entity_id": {"type": "string"},

```

```

    "role": {"type": "string"},
    "index_binding": {"type": "object"},
    "aggregation_axes": {
      "type": "array",
      "items": {"type": "string"}
    },
    "lag_or_offset": {
      "type": ["string", "null"]
    }
  },
  "quantifiers": {
    "type": "array",
    "items": {"type": "string"}
  },
  "condition": {
    "type": ["string", "null"]
  },
  "parameter_refs": {
    "type": "array",
    "items": {"type": "string"}
  },
  "cross_instance": {"type": "boolean"},
  "coupling_active": {"const": true},
  "source_spans": {
    "type": "array",
    "minItems": 1,
    "items": {"type": "string"}
  },
  "confidence": {
    "type": "number",
    "minimum": 0,
    "maximum": 1
  }
}
},
"unresolved_items": {
  "type": "array",
  "items": {
    "type": "object",
    "required": ["type", "description"],
    "properties": {
      "type": {"type": "string"},
      "description": {"type": "string"}
    }
  }
}
}
}

```

注意：**confidence 绝不能直接进入 operational complexity metric**。否则 complexity 会受“哪个 LLM 做 annotator”影响，从而不再 problem-intrinsic。confidence 只用于 QC；最终 graph 必须经过 consensus/adjudication。

## 五类示例对照

### 简单 Product-Mix LP

题意：

工厂生产 A、B 两种产品。每种产品消耗 labor 和 material。总 labor/material 有上限，最大化利润。

CSDE:

$$V_S = \{\text{production}(\text{product})\}.$$

不是 entities:

$$\text{profit}(\text{product}), \text{labor\_usage}(\text{product}), \text{labor\_capacity},$$

因为它们是 parameters。

Semantic obligations:

$$\begin{aligned} o_1 &= \text{labor capacity}, & \sigma(o_1) &= \{\text{production}\}, \\ o_2 &= \text{material capacity}, & \sigma(o_2) &= \{\text{production}\}. \end{aligned}$$

objective:

$$\text{max profit from production}$$

单独保存。

这个案例非常重要：entity-primal graph 只有一个 node，但 obligation graph 中：

$$o_1 \leftrightarrow o_2$$

因为二者共同约束 production。它证明为什么我们不能只计算  $G_V$ 。

### Transportation

题意：

从多个 warehouses 向多个 markets 发货。每个 warehouse 有 supply；每个 market 必须满足 demand；最小化运输成本。

CSDE:

$$\text{shipment}(\text{origin}, \text{destination}).$$

obligations:

$$\begin{aligned} o_{\text{supply}} : \sigma &= \{\text{shipment}\}, \\ o_{\text{demand}} : \sigma &= \{\text{shipment}\}. \end{aligned}$$

两者都:

```
"cross_instance": true
```

因为分别跨 destinations/origins 聚合。

不创建:

```
warehouse_capacity  
market_demand  
shipping_cost
```

nodes。

### Capacitated Facility Location

CSDE:

$$\begin{aligned} A &= \texttt{customer\_assignment(customer, facility)} \\ F &= \texttt{facility\_open(facility)}. \end{aligned}$$

obligations:

$$\begin{aligned} o_1 : \text{each customer assigned exactly once, } \sigma(o_1) &= \{A\}, \\ o_2 : \text{assignment only to open facility, } \sigma(o_2) &= \{A, F\}, \\ o_3 : \text{facility capacity, } \sigma(o_3) &= \{A, F\}. \end{aligned}$$

因此虽然  $o_2, o_3$  support 完全一样，它们必须保留为两个 hyperedges。

### Job-Shop Scheduling

假设每个 operation 的 machine 已知，但 machine 上的顺序需要决定。

可以定义:

$$S = \texttt{operation\_start(job, operation)}$$

和

$$R = \texttt{relative\_order(operation\_a, operation\_b, machine)}.$$

obligations:

$$O_{\text{precedence}} : \{ S \}$$

表示 job technological precedence;

$$O_{\text{machine\_nonoverlap}} : \{ S, R \}.$$

若 MILP 为 non-overlap 使用 Big- $M$ ，其 Big- $M$  constant 是 parameter；若引入一堆 solver-specific auxiliaries，也不成为额外 semantic entities。

若 makespan 用辅助变量  $C_{\max}$  实现，但题面只是 “minimize the completion time of the final schedule”，则不要仅因为一种 MILP formulation 有  $C_{\max}$  就自动加入 semantic node；objective semantic scope 可以直接指 operation timing。

### Capacitated Vehicle Routing

建议 semantic entities:

$$\begin{aligned} R &= \texttt{route\_arc(vehicle,from,to)} \\ S &= \texttt{customer\_service(customer,vehicle)} \end{aligned}$$

以及必要时:

$$U = \texttt{vehicle\_used(vehicle)}.$$

典型 obligations:

$$\begin{aligned} \text{customer exactly once} &: \{ S \} \\ \text{route-service consistency} &: \{ R, S \} \\ \text{route flow conservation} &: \{ R \} \\ \text{vehicle capacity} &: \{ S \} \\ \text{depot departure activation} &: \{ R, U \}. \end{aligned}$$

一个 MTZ formulation 可能另外声明:

$$u_i$$

或者 load progression variable:

$$l_{ki}.$$


前者默认不进入 semantic graph；后者只有在题面本身赋予 “车辆沿路线实时载重状态” 独立业务语义时才进入。

这与最近针对 VRP 的 constraint-injection 工作尤其相关：该工作明确指出仅 objective equivalence 会漏掉 **spurious over-constraint** 与 **silent constraint omission**，并使用 feasible probes 与 one-constraint-violating probes 检测 constraint-level semantic errors。 <sup>16</sup>

# Hypergraph 构建算法与拓扑约定

## 从文本构造 $H_S$

整个流程应该是 “AI semantic extraction + deterministic post-processing”，而不是让 AI 自己算 graph metrics。IR2Solve 的经验也支持 structured LLM output 后接 deterministic verification/compilation，而不是把所有工作都交给自由文本生成。 17



## Deterministic canonicalization pipeline

伪代码如下：

```
function BUILD_SEMANTIC_HYPERGRAPH(instance):

    assert instance contains complete problem text
    validate input schema

    # Stage A: Exogenous Layer
    sets      <- extract_sets(instance)
    parameters <- extract_exogenous_parameters(instance)

    # Stage B: Candidate endogenous concepts
    mentions <- AI_extract_endogenous_decision_relevant_mentions(
        text=instance.problem_text,
        data_semantics=instance.parameter_tables_inline
    )
```

```

# Stage C: Canonicalization
entities <- empty map

for mention in mentions:
    if is_exogenous(mention):
        continue

    if is_pure_formulation_auxiliary(mention):
        continue

    key <- canonical_key(
        semantic_role=mention.role,
        argument_roles=mention.index_roles,
        temporal_grain=mention.temporal_grain,
        quantity_kind=mention.quantity_kind
    )

    entities[key] <- merge_alias_evidence(entities[key], mention)

# Stage D: Feasibility-rule extraction
raw_rules <- AI_extract_business_physical_logical_rules(instance)

obligations <- []

for rule in raw_rules:

    if is_objective_only(rule):
        store_in_objective(rule)
        continue

    atomic_rules <- split_into_independently_falsifiable_rules(rule)

    for r in atomic_rules:

        if is_generic_domain_declaration_only(r):
            attach_domain_metadata(r)
            continue

        support <- semantic_entities_needed_to_evaluate(r)

        if support is empty:
            flag_for_review(r)
            continue

        slots <- extract_incidence_slots(
            rule=r,
            support=support
        )

        obligations.append(

```

```

obligation(
  semantic_identity=normalize_rule_semantics(r),
  support=unique(support),
  incidence_slots=slots,
  parameter_refs=extract_parameter_refs(r),
  cross_instance=detect_cross_instance(slots),
  source_spans=get_evidence(r)
)
)

# Stage E: De-duplication
# Remove repeated paraphrases of the SAME obligation,
# but preserve different obligations with identical support.
obligations <- semantic_deduplicate(obligations)

# Stage F: Hard validation
assert every obligation has source evidence
assert no parameter appears as entity
assert objective excluded from obligation set
assert all entity references are valid

return H_S(entities, obligations, metadata)

```

## 从 $H_S$ 到 incidence matrix

令：

$$n = |V_S|, \quad m = |O_S|.$$

定义 binary incidence matrix：

$$B \in \{0, 1\}^{m \times n},$$

其中：

$$B_{ov} = \begin{cases} 1, & v \in \sigma(o), \\ 0, & \text{otherwise.} \end{cases}$$

注意：即使两个 obligations 有完全相同 support，它们仍是  $B$  中两行不同的 rows。

定义总 incidence 数：

$$L = \sum_{o \in O} |\sigma(o)| = \sum_{o, v} B_{ov}.$$

## Entity-primal graph

由 hypergraph 构造：

$$G_V = (V_S, E_V).$$

对于：

$$u / v, =$$

若存在 obligation：

$$o : u, v \in \sigma(o),$$

则：

$$(u, v) \in E_V.$$

也就是把每一个 hyperedge 的 vertices clique-expand。

CSP 文献中的 primal/Gaifman graph 采用同类思想，即同一 constraint scope 中的 variables 被连接；constraint incidence structure 和 treewidth 是 CSP structural complexity 理论的核心对象。 <sup>13</sup>

但再次强调：

$$\boxed{G_V^{semantic-family} /} = G_{CSP}^{scalar}.$$

因此我们使用 treewidth 是为了测 **global semantic interaction structure**，而不是直接调用 CSP tractability theorem。

## Weighted entity interaction matrix

定义：

$$P_{uv} = \frac{1}{m} \sum_{o=1}^m B_{ou} B_{ov}, \quad u / v \quad =$$

并定义：

$$P_{uu} = 0.$$

所以  $P_{uv}$  表示：

随机选择一个 semantic obligation，它同时涉及  $u, v$  两个 decision entities 的频率。

这是我们之后 spectral metric 的基础。

## Obligation-intersection graph

这是 v1 规范相较此前讨论最值得新增的一层。

定义：

$$G_O = (O, E_O),$$

其中：

$$(o_i, o_j) \in E_O \iff \sigma(o_i) \cap \sigma(o_j) \neq \emptyset. \quad =$$

weighted adjacency:

$$W_{ij} = \frac{|\sigma(o_i) \cap \sigma(o_j)|}{|\sigma(o_i) \cup \sigma(o_j)|}, \quad i \neq j, \quad =$$

即 Jaccard overlap。

若无交集：

$$W_{ij} = 0.$$

这解决了最明显的 degeneracy：

$$V_S = \{\text{production}\}$$

而：

$$O_S = \{\text{labor, material, market, emissions}\}.$$

此时：

$$G_V$$

没有 edges,

但：

$$G_O = K_4.$$

因此可以区分：

“只有一个 decision concept，规则却高度堆叠”

和

“只有一个 decision concept，也只有一个简单 rule”。

## Family-level 的核心原则

主实验绝不能用 expanded scalar graph。

MIPLIB-NL 官方统计显示其中位规模已经是约 2,183 variables 与 1,388 constraints，最大 constraints 超过一百万；其设计本身就是为了从这种 industrial-scale flattened formulation 恢复 compact structure。 <sup>14</sup>

如果：

$$x_{ijt}, \quad |I| = 100, |J| = 100, |T| = 365,$$

我们仍然只有：

`shipment(origin,destination,period)`

一个 semantic entity family。

如果：

$$\sum_j x_{ijt} \leq C_{it} \quad \forall i, t,$$

我们仍然只有：

`origin_period_shipping_capacity`

一个 obligation family。

否则我们测到的主要是 **instance scale**，而不是 **modeling/semantic coupling**。

这也解释了为什么 `cross_instance` metadata 必不可少。

## Operational Complexity 向量与计算规范

先定义我们到底在测什么

建议暂时把本论文中的量命名为：

|                                                                                    |
|------------------------------------------------------------------------------------|
| $\text{OC-HG}^{(S)}$ : Semantic Hypergraph Operational-Structure Complexity Vector |
|------------------------------------------------------------------------------------|

中文可以写：

**语义超图运作问题结构复杂度向量**

它暂时不是“Operational Problem Solving Complexity 的完整定义”，而是其最有希望的 **constraint-structure / modeling-difficulty component**。

这是一个重要的学术降格处理：我们现在还没有证据证明 data understanding、objective interpretation、uncertainty、solver strategy 等全部难度都可以由 constraint graph 表达，所以论文不应先验地把它叫作“全部 operational complexity”。

核心 hypothesis 是：

$$\text{OC-HG}^{(S)} \rightarrow \text{semantic/formulation failure risk.}$$

至于：

solver runtime, branch-and-bound nodes, optimality gap

继续属于独立：

$\mathbf{C}_{\text{computational}}$

axis, 而不进入 intrinsic semantic definition。OPT-Engine 自身也把 exact LP/MIP setting 与未来的 heuristics、runtime、optimality-gap、nonlinear/stochastic/dynamic extensions 区分开。 <sup>12</sup>

## 基础量

令：

$$s_o = |\sigma(o)|.$$

则：

$$n = |V|, \quad m = |O|,$$

$$L = \sum_o s_o,$$

$$\bar{a} = \frac{L}{m}.$$

其中  $\bar{a}$  是 mean hyperedge arity。

注意一个非常重要的 exact relation：

$$D_I = \frac{L}{nm} = \frac{\bar{a}}{n}$$

因此  $D_I$  和  $\bar{a}$  数学上不是独立 features。pilot 可以同时报告，但正式 regression 不能把两者当作独立解释变量。

## Rule overlap

对于任意两条 obligations：

$$k_{ij} = |\sigma(o_i) \cap \sigma(o_j)|.$$

定义相交 pair 数：

$$N_+ = \sum_{i < j} \mathbf{1}(k_{ij} > 0).$$

Intersection density：

$$D_{\cap} = \frac{N_+}{\binom{m}{2}}$$

表示 “有多少比例的 rule pairs 共享至少一个 decision concept”。

Mean positive overlap：

$$O_+ = \frac{1}{N_+} \sum_{i < j: k_{ij} > 0} k_{ij}$$

表示相交 rule pair 平均共享多少 entity families。

Conditional Jaccard:

$$J_+ = \frac{1}{N_+} \sum_{i < j: k_{ij} > 0} \frac{k_{ij}}{s_i + s_j - k_{ij}}$$

表示已经发生 overlap 后，其相对强度。

若计算 all-pair Jaccard:

$$J_{\text{all}} = \frac{1}{\binom{m}{2}} \sum_{i < j} J_{ij},$$

则有 exact identity:

$$J_{\text{all}} = D_{\cap} J_+$$

所以不能把:

$$D_{\cap}, J_+, J_{\text{all}}$$

三个同时放进最终 regression。

## Spectral coupling

对 weighted entity matrix  $P$ :

$$\rho(P) = \lambda_{\max}(P)$$

因为  $P$  是 symmetric nonnegative matrix。

定义:

$$C_{\text{spec}}^V = \frac{\rho(P)}{n-1}$$

对于  $n < 2$ , 定义为 0。

由于:

$$0 \leq P_{uv} \leq 1$$

且最大 row sum 不超过  $n-1$ :

$$\rho(P) \leq \max_u \sum_v P_{uv} \leq n-1,$$

所以:

$$0 \leq C_{\text{spec}}^V \leq 1.$$

这是我们提出的 **normalization**，不是已有 OR literature 中的公认 complexity index。

obligation graph 同理：

$$C_{\text{spec}}^O = \frac{\rho(W)}{m-1}$$

其中：

$$0 \leq W_{ij} \leq 1.$$

它测的是：

是否存在一个大的、相互重叠的 rule-interaction mode。

## Treewidth coupling

对于 binary entity-primal graph：

$$G_V,$$

定义：

$$C_{\text{tw}}^V = \frac{\text{tw}(G_V)}{n-1}$$

其中：

$$0 \leq C_{\text{tw}}^V \leq 1.$$

tree：

$$\text{tw} = 1,$$

clique：

$$\text{tw}(K_n) = n - 1.$$

Treewidth 可以理解为“图离树状可分解结构有多远”的一种 width measure。固定小  $k$  时，经典结果可以在线性时间识别 treewidth 是否不超过  $k$  并构造对应 decomposition。<sup>18</sup> CSP 中 constraint-incidence structure 与 treewidth/hypergraph width 对算法复杂度具有基础性影响。<sup>13</sup>

但 semantic treewidth 的论文表述应该是：

“CSP theory motivates treewidth as a global interaction/decomposability descriptor.”

而不能写：

“我们的 semantic treewidth 已经证明决定 OR computational complexity。”

这两句话的理论强度完全不同。

obligation side:

$$C_{\text{tw}}^o = \frac{\text{tw}(G_o)}{m-1}.$$

### Treewidth 的实际计算策略

对于本次 12-anchor family graphs，绝大多数预计很小，优先 exact。

工程上推荐：

小图：

branch-and-bound exact treewidth。

QuickBB 是经典 complete anytime branch-and-bound algorithm，并结合 minor-min-width lower bound 与 min-fill upper bound。 19

中/大图：

维护：

$$LB \leq \text{tw}(G) \leq UB.$$

若：

$$LB = UB,$$

得到 exact treewidth。

否则报告：

$$C_{\text{tw}} \in \left[ \frac{LB}{N-1}, \frac{UB}{N-1} \right]$$

而不要用 midpoint 假装 exact。

PACE treewidth competitions 本身也长期区分 exact 和 heuristic tracks，反映了实践中 exact/heuristic decomposition 的不同计算角色。 20

第一版工程默认可以设：

```
N <= 25:
    try exact branch-and-bound
else:
    lower bound + min-fill/min-degree upper bound
```

但 25 只是我们实现的 configurable engineering cutoff, 不是数学定理。

## Hubness

使用 simple graph 上 Freeman-style degree centralization:

$$C_{\text{hub}}(G) = \frac{\sum_v (d_{\text{max}} - d_v)}{(N-1)(N-2)}$$

对于:

$$N < 3$$

定义 0。

其归一化使 star 达到 1, 而 regular graph 为 0; Freeman centralization 的核心思想正是用节点 centrality 差异刻画整体网络的集中程度。 21

因此:

$$C_{\text{hub}}^V$$

高表示很多 decision concepts 通过一个少数核心 entity 发生交互。

它与 treewidth 完全不同:

star:

$$C_{\text{hub}} = 1, \quad C_{\text{tw}} \approx 0$$

而 clique:

$$C_{\text{hub}} = 0, \quad C_{\text{tw}} = 1.$$

## Cycle rank 与 normalized cycle density

对于 simple undirected graph:

$$G = (V, E)$$

且 connected components 数为  $c$ , cyclomatic number:

$$\mu(G) = |E| - |V| + c.$$

它表示相对于 spanning forest 多出的独立 cycle 数。

对  $N \geq 3$ , 本文建议 normalization:

$$C_{\text{cyc}}(G) = \frac{\mu(G)}{(N-1)(N-2)/2}$$

因为 complete graph:

$$K_N$$

的 cycle rank 是:

$$\binom{N}{2} - N + 1 = \frac{(N-1)(N-2)}{2}.$$

因此:

$$C_{\text{cyc}} \in [0, 1].$$

同时必须保存 raw:

$$\mu.$$

因为 normalized score 有时会掩盖 “4 个独立 cycles” 和 “400 个独立 cycles” 的规模差异。

## Largest connected component

$$C_{\text{LCC}} = \frac{|V_{\text{largest component}}|}{N}$$

它反映问题是否被分解为多个相对独立的 semantic modules。

一个:

$$C_{\text{LCC}} \ll 1$$

的问题可能本质上是多个弱耦合子问题，而不是一个真正全局耦合问题。

## 完整 metric specification 表

设 entity graph 为  $G_V$ ，其节点数  $n$ 、边数  $e_V$ ；obligation graph 为  $G_O$ ，节点数  $m$ 、边数  $e_O$ 。

| 指标                   | 数学定义                 | 主要输入        | 典型计算复杂度            | 解释                              | 主要陷阱                              |
|----------------------|----------------------|-------------|--------------------|---------------------------------|-----------------------------------|
| Entity families $n$  | $n =  V $            | CSDE        | $O(1)$ after parse | semantic concept count          | 受 canonicalization 粒度影响           |
| Obligations $m$      | $m =  O $            | obligations | $O(1)$             | rule-family burden              | rule splitting policy 必须固定        |
| Incidences $L$       | $\sum_o  \sigma(o) $ | hyperedges  | $O(L)$             | total semantic incidence burden | 与 $n, m$ 强相关                      |
| Mean arity $\bar{a}$ | $L/m$                | hyperedges  | $O(L)$             | 每条 rule 涉及多少 concepts           | 与 $D_I$ exact redundant given $n$ |

| 指标                            | 数学定义                                                   | 主要输入               | 典型计算复杂度                                  | 解释                               | 主要陷阱                                     |
|-------------------------------|--------------------------------------------------------|--------------------|------------------------------------------|----------------------------------|------------------------------------------|
| Incidence density $D_I$       | $L/(nm)$                                               | $B$                | $O(L)$                                   | normalized support breadth       | $D_I = \bar{a}/n$                        |
| Intersection density $D_\cap$ | $N_+/\binom{m}{2}$                                     | edge supports      | sparse: $O(L + \sum_v d_v^2)$            | 有多少 rule pairs 相互作用              | 同一 family 但 disjoint index subsets 可能被高估 |
| Mean overlap $O_+$            | $\frac{1}{N_+} \sum k_{ij}$                            | supports           | 同上                                       | 重叠时共享几个 concepts                 | 非 normalized; 受 arity 影响                 |
| Conditional Jaccard $J_+$     | $\frac{1}{N_+} \sum \frac{k_{ij}}{s_i + s_j - k_{ij}}$ | supports           | 同上                                       | overlap 相对强度                     | $N_+ = 0$ 时 conditional mean 未定义         |
| Entity spectral               | $\rho(P)/(n-1)$                                        | weighted primal    | dense eig $O(n^3)$ ; sparse iterative 更低 | global weighted interaction mode | 可能与 density/degree 强相关                   |
| Entity treewidth              | $\text{tw}(G_V)/(n-1)$                                 | binary primal      | exact combinatorial; heuristic/bounds    | global non-tree-like interaction | hyperedge clique expansion 会放大高 arity    |
| Entity hubness                | Freeman degree centralization                          | $G_V$              | $O(n + e_V)$                             | 是否由核心 entity 主导                  | regular dense graph hubness 可为 0         |
| Entity cycle rank             | $e_V - n + c$                                          | $G_V$              | $O(n + e_V)$                             | independent cycles               | 与 edge density 有机械关系                     |
| Entity cycle density          | $\mu/[(n-1)(n-2)/2]$                                   | $G_V$              | $O(n + e_V)$                             | normalized cyclic entanglement   | 小图离散性大                                   |
| Entity LCC                    | $N_{\max}/n$                                           | $G_V$              | $O(n + e_V)$                             | global connectivity              | 不区分 component 内 topology                 |
| Obligation spectral           | $\rho(W)/(m-1)$                                        | Jaccard rule graph | dense $O(m^3)$                           | global rule-rule overlap         | duplicate paraphrase 若未去重会虚高             |
| Obligation treewidth          | $\text{tw}(G_O)/(m-1)$                                 | rule graph         | 同 treewidth                              | rule interaction decomposability | 大量 unary rules 可产生很高值                    |
| Obligation hubness            | 同 Freeman formula                                      | $G_O$              | $O(m + e_O)$                             | 是否少数 rule 是 interaction hub      | 先作为 diagnostic                           |
| Obligation cycle density      | 同上                                                     | $G_O$              | $O(m + e_O)$                             | cyclic rule overlap              | 与 density 冗余可能高                          |

| 指标             | 数学定义                    | 主要输入  | 典型计算复杂度      | 解释          | 主要陷阱           |
|----------------|-------------------------|-------|--------------|-------------|----------------|
| Obligation LCC | largest component / $m$ | $G_O$ | $O(m + e_O)$ | rules 是否分模块 | 先作为 diagnostic |

其中  $d_v$  是 entity  $v$  incident 的 obligation 数。利用 inverted index:

```
entity -> incident obligations
```

即可避免 naïve:

$$O(m^2n)$$

的所有 pairs 比较。

## 数值稳定性与软件规范

建议 metric engine 固定:

```
float type      = float64
canonical order = sort by entity_id / obligation_id
matrix symmetry = (M + M.T) / 2
spectral solver = eigvalsh for small dense graphs
                 Lanczos/eigsh for large sparse graphs
epsilon         = 1e-12
```

若 numerical eigensolver 返回:

$$-10^{-15}$$

这种理论上应为 0 的小 numerical artifact, 应 clip 至 0。

Conditional metrics:

$$N_+ = 0$$

时不能在数学报告里假装“conditional mean 等于 0”。建议 API 返回:

```
{
  "mean_positive_overlap": {
    "value": 0.0,
    "defined": false
  }
}
```

下游统计时视为 structural zero/undefined category, 而不是普通观测值。

Treewidth:

```
{
  "treewidth": {
    "status": "exact",
    "lower_bound": 4,
    "upper_bound": 4,
    "value": 4
  }
}
```

或：

```
{
  "treewidth": {
    "status": "bounded",
    "lower_bound": 7,
    "upper_bound": 10,
    "value": null
  }
}
```

### 一个更深的理论警告：primal treewidth 不是终点

一个高元 hyperedge：

$$e = \{v_1, \dots, v_{20}\}$$

经过 clique expansion 会产生：

$$K_{20}$$

从而：

$$\text{tw} = 19.$$

但 CSP theory 已经明确指出，当 constraints 具有 unbounded arity 时，primal treewidth 不再是最一般的 tractability descriptor；fractional hypertree width、submodular width 等是真正 hypergraph-native 的 generalizations。 <sup>22</sup>

所以 future extension 非常自然：

$$\text{ghw}(H_S), \quad \text{fhw}(H_S), \quad \text{subw}(H_S).$$

但我不建议现在进入 MVP。理由不是这些理论不重要，而是：

1. 我们首先要证明 semantic graph annotation 本身可靠；
2. treewidth 已经足够测试 “global decomposability 是否预测 modeling failure” ；
3. semantic family hyperedge 的含义与 CSP scalar hyperedge 仍不同；
4. 2026 年仍有专门工作研究 generalized/fractional hypertree width 的 exact computation，说明这不是一个应随便附加的轻量 metric。 <sup>23</sup>

论文中把这类 hypergraph-native widths 放进 extension/future analysis 会比第一版全部纳入更稳妥。

## 复杂示例与逐项计算

下面使用一个人为构造但具有 **routing + facility + inventory coupling** 的小型 **operational instance**。它的目标不是求出 optimum，而是让每一个 complexity metric 都有明确结构。

### 问题与参数

有两个 depots:

$$D = \{d_1, d_2\},$$

三个 customers:

$$C = \{c_1, c_2, c_3\},$$

两辆 vehicles:

$$K = \{k_1, k_2\}.$$

customer demand:

$$q_{c_1} = 4, \quad q_{c_2} = 5, \quad q_{c_3} = 3.$$

depot capacity:

$$Cap_{d_1} = 10, \quad Cap_{d_2} = 9.$$

facility fixed cost:

$$f_{d_1} = 12, \quad f_{d_2} = 10.$$

车辆最大 duty time:

$$H_{k_1} = H_{k_2} = 30.$$

loading/service time:

$$\alpha = 0.5$$

per delivered unit。

locations 按:

$$(d_1, d_2, c_1, c_2, c_3)$$

给出 travel-time matrix:

$$T = \begin{bmatrix} 0 & 6 & 4 & 7 & 8 \\ 6 & 0 & 7 & 3 & 5 \\ 4 & 7 & 0 & 4 & 6 \\ 7 & 3 & 4 & 0 & 3 \\ 8 & 5 & 6 & 3 & 0 \end{bmatrix}.$$

## 六个 CSDE families

定义：

$$A = \text{customer\_assignment}(\text{customer}, \text{depot})$$

$$F = \text{depot\_open}(\text{depot})$$

$$R = \text{route\_arc}(\text{depot}, \text{vehicle}, \text{from}, \text{to})$$

$$V = \text{vehicle\_active}(\text{depot}, \text{vehicle})$$

$$Q = \text{delivered\_quantity}(\text{depot}, \text{vehicle}, \text{customer})$$

$$I = \text{inventory\_allocated}(\text{depot}).$$

因此：

$$n = 6.$$

## 十条 semantic obligations

| ID       | 业务义务                                          | 一种可能数学表达                                                            | Support       |
|----------|-----------------------------------------------|---------------------------------------------------------------------|---------------|
| $o_1$    | customer 恰好分配给一个 depot                        | $\sum_d A_{cd} = 1$                                                 | $\{A\}$       |
| $o_2$    | 只能分配给 open depot                              | $A_{cd} \leq F_d$                                                   | $\{A, F\}$    |
| $o_3$    | route flow conservation                       | $\sum_j R_{dkji} = \sum_j R_{dkij}$                                 | $\{R\}$       |
| $o_4$    | 被 depot 分配的 customer 必须由该 depot route 访问      | $\sum_k \sum_j R_{dk,cj} = A_{cd}$                                  | $\{R, A\}$    |
| $o_5$    | route 使用必须对应 active vehicle                   | $\sum_j R_{dk,dj} = V_{dk}$                                         | $\{R, V\}$    |
| $o_6$    | travel + loading 不超过 vehicle duty             | $\sum_{ij} t_{ij} R_{dkij} + \alpha \sum_c Q_{dkc} \leq H_k V_{dk}$ | $\{R, V, Q\}$ |
| $o_7$    | demand 通过其 assigned depot 完成                  | $\sum_k Q_{dkc} = q_c A_{cd}$                                       | $\{Q, A\}$    |
| $o_8$    | depot 发出的数量不超过 allocated inventory            | $\sum_{k,c} Q_{dkc} \leq I_d$                                       | $\{I, Q\}$    |
| $o_9$    | inventory allocation 受 open depot capacity 限制 | $I_d \leq Cap_d F_d$                                                | $\{I, F\}$    |
| $o_{10}$ | vehicle 只能在 open depot activated              | $V_{dk} \leq F_d$                                                   | $\{V, F\}$    |

因此：

$$m = 10.$$

objective 例如：

$$\min \sum_d f_d F_d + \sum_{dkij} t_{ij} R_{dkij}$$

单独保存，不构成 hyperedge。

## Incidence matrix

按：

$$(A, F, R, V, Q, I)$$

排序，得到：

$$B = \begin{array}{c|cccccc} & A & F & R & V & Q & I \\ \hline o_1 & 1 & 0 & 0 & 0 & 0 & 0 \\ o_2 & 1 & 1 & 0 & 0 & 0 & 0 \\ o_3 & 0 & 0 & 1 & 0 & 0 & 0 \\ o_4 & 1 & 0 & 1 & 0 & 0 & 0 \\ o_5 & 0 & 0 & 1 & 1 & 0 & 0 \\ o_6 & 0 & 0 & 1 & 1 & 1 & 0 \\ o_7 & 1 & 0 & 0 & 0 & 1 & 0 \\ o_8 & 0 & 0 & 0 & 0 & 1 & 1 \\ o_9 & 0 & 1 & 0 & 0 & 0 & 1 \\ o_{10} & 0 & 1 & 0 & 1 & 0 & 0 \end{array} .$$

总 incidence：

$$L = 1 + 2 + 1 + 2 + 2 + 3 + 2 + 2 + 2 + 2 = 19.$$

因此：

$$\bar{a} = \frac{19}{10} = 1.9$$

以及：

$$D_I = \frac{19}{6 \times 10} = 0.3167$$

## Rule-pair overlap

总共有：

$$\binom{10}{2} = 45$$

个 obligation pairs。

其中 support intersection 非空的有：

$$N_+ = 21.$$

因此：

$$D_{\cap} = \frac{21}{45} = 0.4667$$

所有 positive intersections 的 cardinality 总和为：

$$22.$$

所以：

$$O_+ = \frac{22}{21} = 1.0476$$

这些 21 个 positive pairs 的 Jaccard 值分布为：

$$5 \times \frac{1}{2},$$

$$11 \times \frac{1}{3},$$

$$4 \times \frac{1}{4},$$

$$1 \times \frac{2}{3}.$$

因此：

$$\sum J_{ij} = \frac{5}{2} + \frac{11}{3} + 1 + \frac{2}{3} = \frac{47}{6}.$$

所以：

$$J_+ = \frac{47/6}{21} = \frac{47}{126} \approx 0.3730$$

而 all-pairs mean Jaccard：

$$\begin{aligned} J_{\text{all}} &= D_{\cap} J_+ \\ &= 0.4667 \times 0.3730 \approx 0.1741. \end{aligned}$$

再次说明它是 redundant metric。

## Entity weighted primal matrix

按照：

$$(A, F, R, V, Q, I)$$

计算：

$$P_{uv} = \frac{\#\{\text{obligations jointly containing } u, v\}}{10},$$

得到：

$$P = \begin{bmatrix} 0 & 0.1 & 0.1 & 0 & 0.1 & 0 \\ 0.1 & 0 & 0 & 0.1 & 0 & 0.1 \\ 0.1 & 0 & 0 & 0.2 & 0.1 & 0 \\ 0 & 0.1 & 0.2 & 0 & 0.1 & 0 \\ 0.1 & 0 & 0.1 & 0.1 & 0 & 0.1 \\ 0 & 0.1 & 0 & 0 & 0.1 & 0 \end{bmatrix}.$$

最大 eigenvalue：

$$\rho(P) \approx 0.3535106.$$

因此：

$$C_{\text{spec}}^V = \frac{0.3535106}{5} = 0.07070$$

注意这个数很低并不意味着“问题毫无 coupling”；因为  $P$  同时被 obligation frequency 归一化。它需要与 treewidth、rule overlap 等联合解释，这也是 vector-first 的意义。

## Entity-primal topology

非零 pair edges：

$$E_V = \{AF, AR, AQ, FV, FI, RV, RQ, VQ, QI\}.$$

所以：

$$|E_V| = 9.$$

degrees：

$$d_A = 3, \quad d_F = 3, \quad d_R = 3, \quad d_V = 3, \quad d_Q = 4, \quad d_I = 2.$$

整个图 connected：

$$c = 1.$$

## Hubness

$$d_{\max} = 4.$$

分子：

$$(4 - 3) + (4 - 3) + (4 - 3) + (4 - 3) + (4 - 4) + (4 - 2) = 6.$$

分母：

$$(6 - 1)(6 - 2) = 20.$$

因此：

$$C_{\text{hub}}^V = \frac{6}{20} = 0.3000$$

### Cycle rank

$$\mu_V = 9 - 6 + 1 = 4.$$

最大 cycle rank：

$$\frac{(6-1)(6-2)}{2} = 10.$$

因此：

$$C_{\text{cyc}}^V = \frac{4}{10} = 0.4000$$

### LCC

全部 6 个 nodes connected：

$$C_{\text{LCC}}^V = 1.$$

### Treewidth

该 6-node graph 的 exact treewidth：

$$\text{tw}(G_V) = 3.$$

所以：

$$C_{\text{tw}}^V = \frac{3}{5} = 0.6000$$

这里可以看到一个很有意思的 topology：

$$C_{\text{hub}} = 0.3$$

并不特别高，

但：

$$C_{\text{tw}} = 0.6$$

和：

$$C_{\text{cyc}} = 0.4$$

已经不低。

因此它不像 star，而更接近多路径互联结构。

## Obligation-intersection graph

$G_O$  有：

$$m = 10$$

个 nodes 和：

$$|E_O| = 21$$

条 edges。

十个 obligation degrees：

$$(3, 5, 3, 6, 4, 6, 5, 3, 3, 4).$$

其 weighted Jaccard matrix 的 spectral radius：

$$\rho(W) \approx 1.6928453.$$

因此：

$$C_{\text{spec}}^O = \frac{1.6928453}{9} = 0.18809$$

exact treewidth：

$$\text{tw}(G_O) = 4,$$

所以：

$$C_{\text{tw}}^O = \frac{4}{9} = 0.44444$$

obligation-side hubness：

$$d_{\max} = 6.$$

分子：

$$\sum_i (6 - d_i) = 18.$$

分母：

$$(10 - 1)(10 - 2) = 72.$$

于是：

$$C_{\text{hub}}^O = 0.25$$

cycle rank:

$$\mu_O = 21 - 10 + 1 = 12.$$

归一化最大值:

$$\frac{9 \times 8}{2} = 36.$$

于是:

$$C_{\text{cyc}}^O = \frac{12}{36} = 0.3333$$

并且:

$$C_{\text{LCC}}^O = 1.$$

## 最终向量

首先报告 structural controls:

$$\mathbf{S} = (n, m, L, \bar{a}) = (6, 10, 19, 1.9)$$

local coupling:

$$\mathbf{C}_{\text{local}} = (D_I, D_{\cap}, J_+) = (0.3167, 0.4667, 0.3730)$$

entity topology:

$$\mathbf{C}_V = (0.0707, 0.6000, 0.3000, 0.4000, 1.0000)$$

按顺序分别是:

$$(C_{\text{spec}}^V, C_{\text{tw}}^V, C_{\text{hub}}^V, C_{\text{cyc}}^V, C_{\text{LCC}}^V).$$

obligation MVP:

$$\mathbf{C}_O = (C_{\text{spec}}^O, C_{\text{tw}}^O) = (0.1881, 0.4444)$$

diagnostics:

$$O_+ = 1.0476,$$

$$C_{\text{hub}}^O = 0.25,$$

$$\mu_V = 4, \quad \mu_O = 12,$$

$$C_{\text{cyc}}^O = 0.3333, \quad C_{\text{LCC}}^O = 1.$$

所以第一版完整 machine-readable vector 可以保存为:

$$\mathbf{OC}_{\text{HG}}^{(S)} = [6, 10, 19, 1.9; 0.3167, 0.4667, 0.3730; 0.0707, 0.6000, 0.3000, 0.4000, 1.0000; 0.1881, 0.4444]$$

但统计分析时**不应把这 15 个数无脑全部扔进 regression**。尤其：

$$\bar{a} \leftrightarrow D_I$$

存在确定性关系；

$$D_{\cap}, J_{+} \leftrightarrow J_{\text{all}}$$

也有确定性关系。正式 experiment 必须先做 redundancy screening。

## 验证实验、MVP 与交付物

### 这套 definition 首先需要验证什么

这套工作存在三个层层递进的 validity 问题：

$$\text{Annotation validity} \rightarrow \text{Metric construct validity} \rightarrow \text{Predictive validity}$$

现在的 12-anchor pilot 主要解决前两个，**不应该拿 12 个样本直接做 “complexity 显著预测 accuracy” 的论文结论**。

首先问：

两个强 AI、一个研究员能不能对同一题稳定地产生同一个  $H_S$ ？

然后问：

我们设计的 graph metrics 是否符合 star/cycle/clique 等明显 topology intuition，而不是变成 problem size 的替身？

最后正式大样本才问：

metrics 是否预测 constraint formulation correctness / feasibility degradation？

ORAgentBench 明确指出 OR difficulty 不应由 instance size 单独代表，并把 formulation structure、constraint coupling、dynamic structure、data scale、problem understanding、solving strategy 分开；这恰好给我们的 discriminant-validity experiment 提供了一个重要参考。 <sup>24</sup>

## 十二个 anchor instances

按我们已经确定的五类 repository，建议固定：

| 来源              | 数量 | 目的                                |
|-----------------|----|-----------------------------------|
| IndustryOR Easy | 2  | real-world wording 下的低/中 coupling |
| IndustryOR Hard | 2  | 对照较复杂 business-rule interaction   |

| 来源                          | 数量        | 目的                                     |
|-----------------------------|-----------|----------------------------------------|
| NL4OPT                      | 2         | clean/simple LP semantic baseline      |
| MIPLIB-NL                   | 2         | industrial structured MILP             |
| LEAN-LLM-OPT Large-scale-OR | 2         | large-scale modeling/data workflow     |
| OPT-Engine                  | 2         | controlled-complexity synthetic anchor |
| <b>总计</b>                   | <b>12</b> | diagnostic pilot                       |

IndustryOR 是 ORLM 项目公开的 real-world OR modeling benchmark; MIPLIB-NL 则提供 verified NL/formal-model/data/reference-solver correspondence; LEAN-LLM-OPT repository 提供 101 个 Large-scale-OR benchmarks; OPT-Engine 覆盖十类 canonical LP/MIP tasks 并进行 controlled structural scaling。 <sup>25</sup>

这 12 个**不要随机抽**，而使用 purposive diagnostic sampling。

选择标准是：

maximize structural contrast, not population representativeness

优先确保包含：

- 低 arity、低 overlap;
- 单一 variable family + 多个 rule families;
- hub-like structure;
- cycle/network-flow structure;
- multi-entity dense coupling;
- routing 或 scheduling;
- 一个明显具有 auxiliary-formulation possibility 的问题;
- 一个 semantic graph 可明显分模块的问题。

MIPLIB-NL 尽量选 `model.md` 清楚、family structure 容易人工核验的两个实例。其官方 benchmark 已有 structure-aware reverse construction 和 independent NL→Opt reconstruction/human-LLM validation, 可以成为我们 algebraic-layer gold 的重要基础。 <sup>6</sup>

## 人工 + 强 AI 混合标注

每个 instance 建议产生三份：

$$H_S^A, \quad H_S^B, \quad H_S^*.$$

其中：

- $A$ : 强模型 A 独立 annotation;
- $B$ : 强模型 B 独立 annotation;
- $H_S^*$ : 研究员 adjudicated final graph.

两次 AI generation 应使用相同 prompt/schema、deterministic/low-temperature setting, 并且互相看不到对方结果。

比较顺序：

### Entity agreement

先按 canonical key 做 matching：

$$K(e) = (\text{role}, \text{index signature}, \text{time semantics}).$$

计算 entity precision / recall / F1。

### Obligation agreement

在 matched entities 后，比较：

$$(\text{normalized semantic label}, \sigma(o)).$$

重点报告：

$$F1_{\text{obligation}}$$

和：

$$F1_{\text{support}}.$$

### Graph agreement

比较：

$$E_V^A \triangle E_V^B$$

以及：

$$E_O^A \triangle E_O^B.$$

### Metric stability

对于每个 metric  $M$ ：

$$\Delta_M = |M(H_A) - M(H_B)|.$$

真正适合称为 problem-intrinsic measure 的指标，必须先证明对 reasonable annotators 足够稳定。

### 不要把 annotator confidence 变成 complexity

例如 GPT annotator 给某题：

confidence = 0.61

另一模型给：

confidence = 0.94

绝不能把它们平均后作为 semantic ambiguity complexity。

因为那测的是：

annotator uncertainty

而不是：

problem property.

正确做法是利用 annotation ensemble 计算 sensitivity：

$$M_{\min}, M_{\max}$$

再经人工 adjudication 得到 final  $M^*$ 。

若某个 metric 对微小 annotation difference 极端敏感，这本身就是其不适合作为 operational complexity 指标的证据。

## Behavioral invariants

这部分非常值得做好，因为它可以在没有大规模 expert gold graph 的情况下提供 validation。

### Parameter-value invariance

把：

$$capacity = 100$$

改成：

$$capacity = 120$$

但 business rule 不变。

理想：

$$H_S(P) = H_S(P')$$

且：

$$\mathbf{OC}_{\text{HG}}^{(S)}(P) = \mathbf{OC}_{\text{HG}}^{(S)}(P').$$

数值变化可以改变 computational difficulty/constraint tightness，但不应自动改变 family-level semantic topology。

ReLoop 证明了 solver-based parameter perturbation 可以作为识别 silent semantic modeling errors 的外部信号，而无需 reference formulation。 <sup>26</sup> 2026 年后续 falsification-based verification 工作还把 numeric

quantities 视为 typed slots, 并从 comparative statics/duality 构造 sound perturbation tests, 说明 parameter perturbation 已经成为 optimization-model verification 中很有理论潜力的工具。 27

### Scale invariance

把:

$$|C| = 10$$

扩大成:

$$|C| = 100,$$

但 rule families、index schemas 不变。

则 family-level:

$$H_S$$

应该保持同构。

这正是我们的 metric 与 “variable count/constraint count complexity” 最直接的分离试验。

### Paraphrase invariance

将:

Every customer must be assigned exactly once.

改写成:

Each customer is required to receive one and only one assignment.

应满足:

$$H_S^{(1)} \simeq H_S^{(2)}.$$

NL4Opt 本来就把问题定义为从语言表述恢复 machine-interpretable meaning; 我们的 canonical layer 则进一步要求 equivalent language surface forms 得到相同 graph。 5

### Alias invariance

将:

plant

替换为:

manufacturing facility

若 operational referent 相同:

$$K(e)$$

应不变。

### Rule-ablation response

若删除唯一一条：

assigned customer must belong to an open facility

则 graph 应恰好删除：

$$O_{\text{assignment} \rightarrow \text{open}}.$$

这是非常强的 unit test：

$$H'_S = H_S \setminus \{o\}.$$

如果 annotator 连这种 controlled intervention 都不能稳定响应，就不适合进入大规模自动 annotation。

### Solver-based semantic QC

对于有 gold/可执行 models 的 subset，可以进一步验证 obligations。

最新 constraint-injection 工作指出 objective-equivalence 的两个 blind spots 是：

spurious over-constraint

和：

silent constraint omission,

并分别用 feasible probes 和 intentionally violating probes 进行检测。 16

我们的 QC 可以利用相同思想：

对于 obligation  $o_i$ ，尝试构造 candidate decision：

$$x^{(-i)}$$

满足：

$$o_j, \quad \forall j \neq i \quad =$$

但违反：

$$o_i.$$

若 gold model 对这个 decision 的行为与 semantic obligation 不一致，就说明：

- semantic annotation 可能错；
- gold model mapping 可能错；

- 或该 obligation 事实上被其他 rules 逻辑蕴含。

第三种情况本身也非常有研究意义，因为它提醒我们：

syntactic obligations / independent feasible-region facets.

这可能成为以后定义 **logical/redundancy coupling** 的方向。

## Face validity

首先建立 synthetic topology controls:

empty/disconnected, chain, star, cycle, clique, two communities + bridge.

预期：

| 拓扑                   | $C_{tw}$      | $C_{hub}$        | $C_{cyc}$ | 直觉                        |
|----------------------|---------------|------------------|-----------|---------------------------|
| chain/tree           | 低             | 依 topology       | 0         | 可分解                       |
| star                 | 低             | <b>最高</b>        | 0         | hub burden                |
| cycle                | 中低            | 0                | $> 0$     | feedback-like interaction |
| clique               | <b>最高</b>     | 0                | <b>最高</b> | dense global entanglement |
| modules              | component 内可高 | variable         | variable  | decomposable              |
| communities + bridge | 中             | bridge-dependent | 中/高       | bottleneck coupling       |

如果我们的 metric engine 算不出这种排序，先修 metric，不要跑 LLM benchmark。

## Scale leakage

对 12 个 anchors，画：

$$M_j \text{ vs } \log n,$$

$$M_j \text{ vs } \log m,$$

以及未来 scalar-expanded size：

$$\log N_{\text{scalar-variable}}, \quad \log N_{\text{scalar-constraint}}.$$

如果所谓 “normalized coupling” 几乎只是：

$$f(\log m)$$

的单调函数，就不能声称它捕获了独立 coupling information。

ORAgentBench 对 difficulty 的核心设计原则正是不能让 instance scale 成为 misleading proxy。 28

## Spearman redundancy matrix

12 个样本阶段只用于 exploratory redundancy:

$$R_{ij} = \rho_S(M_i, M_j).$$

重点观察:

$$D_{\cap}, J_+, C_{\text{spec}}, C_{\text{tw}}, C_{\text{hub}}, C_{\text{cyc}}.$$

例如:

$$|\rho_S| > 0.9$$

可以作为 pilot 中的“高度冗余警报线”，但不应该包装成 universal statistical cutoff。

由于:

$$N = 12,$$

这一步主要做:

feature diagnostics

而不是 significance testing。

尤其不需要通过  $p < 0.05$  来决定哪个 metric “是真的”。

## Representation stress-test

选择 12 个样本中的一个中等复杂度实例，构造三种 formulations:

$F_1$  = canonical compact formulation,

$F_2$  = semantically equivalent split/expanded formulation,

$F_3$  = auxiliary-variable / linearized reformulation.

目标是验证:

$$H_S(F_1) \simeq H_S(F_2) \simeq H_S(F_3)$$

因为 operational problem 没有改变。

而 algebraic:

$$H_A(F_1), \quad H_A(F_2), \quad H_A(F_3)$$

允许不同。

这里需要细分两种 F2 情况:

如果 F2 只是：

$$g_i(x) \leq 0, \quad \forall i \in I$$

展开成：

$$g_1(x) \leq 0, \dots, g_{|I|}(x) \leq 0,$$

family reconstruction 后：

$$H_A(F_1) \simeq H_A(F_2)$$

也应该成立。IR2Solve 明确给出了 finite-index constraint family 与其 scalar conjunction 定义同一 feasible region 的形式化说明。 <sup>29</sup>

因此这类 F2 实际是 **family-recovery unit test**。

更强的 F2 可以使用：

- equality split 成两个 inequalities;
- compact global constraint 拆成多个 constraint families;

这时：

$$H_A$$

可以变化，但：

$$H_S$$

仍必须不变。

F3 则故意引入：

- auxiliary variables;
- Big- $M$  linearization;
- aggregate helper variables;
- alternative flow representation.

此时理论预期是：

$$\boxed{\text{OC}_{\text{HG}}^{(S)} \text{ invariant}}$$

而：

$$\boxed{\text{OC}_{\text{HG}}^{(A)} \text{ may change substantially.}}$$

这会给论文提供非常漂亮的 construct-validity evidence：

**semantic complexity anchors to the operational problem; algebraic complexity responds to representation choice.**

最关键的是不能仅通过：

$$z_{F_1}^* = z_{F_3}^*$$

确认 equivalence。IR2Solve 明确指出相同 optimum 不证明 feasible regions 相同。③ 应采用：

- exhaustive enumeration (小 synthetic instance) ；
- bidirectional feasible-solution checking；
- constraint-injection probes；
- parameter perturbation；
- solver-backed equivalence checks。

## 后续正式 predictive experiment 的目标模型

pilot 通过之后，真正的论文实验应该估计：

$$P(Y_{\text{constraint-correct}} = 1 \mid \mathbf{OC})$$

以及：

$$P(Y_{\text{feasible}} = 1 \mid \mathbf{OC}).$$

例如 logistic mixed model：

$$\text{logit } P(Y_{ij} = 1) = \beta_0 + \beta^\top \mathbf{C}_i + \gamma^\top \mathbf{S}_i + u_{\text{model}(j)} + u_{\text{benchmark}(i)}.$$

其中：

$$\mathbf{C}_i$$

是 coupling metrics；

$$\mathbf{S}_i$$

是：

$$n, m, L$$

等 size controls。

这才真正检验：

coupling 是否在 controlling for scale 后仍预测 LLM failure?

而不是简单发现：

“难题 constraints 更多，所以 accuracy 更低。”

这一步正是我们能够超过 OPT-Engine/ORAgentBench qualitative complexity treatment 的地方。OPT-Engine 已通过 controllable scaling 定位 constraint formulation bottleneck，ORAgentBench 已观察 difficulty 不能被 scale 解释；我们的贡献将是给出一个可以在 benchmark 外部自动计算的 structural predictor。③

## 里程碑式实验时间表

不把进度绑定到具体模型 API 或人为工期，建议按以下“完成条件”推进：

| 阶段                         | 工作                                         | 进入下一阶段的条件                                    |
|----------------------------|--------------------------------------------|----------------------------------------------|
| Definition Freeze          | 固定 CSDE/SOH v1、inclusion/exclusion policy  | 研究员能对 synthetic examples 无歧义标注               |
| Schema Freeze              | JSON schema + validator + canonical naming | synthetic examples 100% schema-valid         |
| Topology Unit Test         | star/cycle/clique/modules                  | metric outputs 符合理论预期                        |
| Anchor Annotation          | 12 个 anchors 双 AI 独立标注                     | 获得 entity/obligation disagreement log        |
| Human Adjudication         | 逐例形成 $H_S^*$                               | 每个 node/edge 有 source evidence               |
| Metric Sanity Pilot        | 全量算 semantic vector                        | 无明显 scale leakage / coding error             |
| Algebraic Pairing          | 从 gold model/model.md 构造 $H_A$             | semantic-algebraic mapping 可审计               |
| Representation Stress Test | F1/F2/F3                                   | $H_S$ invariant、 $H_A$ 差异可解释                 |
| Predictive Expansion       | 扩大 benchmark 样本                            | 开始 accuracy/feasibility degradation modeling |

## 最低可行实现

必须完成的 MVP 可以压缩为六个对象。

第一，`definition_v1.md`，包括：

*CSDE*, *semantic obligation*,  $H_S$ ,  $H_A$ , *inclusion/exclusion*.

第二，`semantic_annotation_prompt_v1.txt`。

第三，`semantic_hypergraph.schema.json`。

第四，`metric_engine.py`，至少实现：

```

validate_graph()
build_incidence_matrix()
build_entity_primal_graph()
build_obligation_graph()

incidence_density()
intersection_density()
mean_positive_overlap()
conditional_jaccard()

```

```
spectral_coupling()
treewidth_or_bounds()
degree_centralization()
cycle_rank()
normalized_cycle_density()
largest_component_ratio()
```

第五，一组 synthetic unit tests:

```
single-node-multi-rule
chain
star
cycle
clique
two-components
two-communities-bridge
```

第六，`anchor12.csv/jsonl`:

```
dataset
instance_id
human_status
entity_count
obligation_count
incidences
all metrics
annotation disagreements
notes
```

## 交付物清单

最终这一个研究模块建议形成以下 repository structure:


```
operational-complexity/
|
|—— definitions/
|   |—— csde_definition_v1.md
|   |—— semantic_obligation_definition_v1.md
|   |—— semantic_vs_algebraic_boundary.md
|   |—— annotation_decision_rules.md
|
|—— schemas/
|   |—— semantic_hypergraph.schema.json
|   |—— algebraic_hypergraph.schema.json
|
|—— prompts/
|   |—— semantic_annotator_v1.txt
```

```

|   |—— annotation_critic_v1.txt
|   |—— adjudication_prompt_v1.txt
|
|—— examples/
|   |—— product_mix.json
|   |—— transportation.json
|   |—— facility_location.json
|   |—— job_shop.json
|   |—— cvrp.json
|   |—— integrated_example_metrics.csv
|
|—— metrics/
|   |—— hypergraph_builder.py
|   |—— projections.py
|   |—— coupling_metrics.py
|   |—— treewidth.py
|   |—— tests/
|
|—— pilot/
|   |—— anchor12_manifest.csv
|   |—— ai_annotations_A/
|   |—— ai_annotations_B/
|   |—— human_adjudicated/
|   |—— metric_results.csv
|   |—— spearman_matrix.csv
|   |—— representation_stress_test/
|
|—— experiment_protocol/
|   |—— pilot_protocol.md
|   |—— quality_control.md
|   |—— predictive_validation_plan.md

```

从论文 conceptual contribution 的角度，最终可以压缩成下面这张逻辑图：



这一定义方向与目前文献之间的关系可以非常准确地表述为：

NL4Opt 证明了 NL→OR 可以被视为 semantic parsing / formulation extraction 问题；  
 MIPLIB-NL 提供了 family-level structural abstraction 与工业级 gold formulation；IR2Solve  
 提供了 semantic generation 与 deterministic solver realization 可分离的直接证据；OPT-  
 Engine 定位了 solver-integrated reasoning 中 constraint formulation 的瓶颈；  
 ORAgentBench 又明确提出 constraint coupling 是不能由 size 替代的 difficulty dimension；  
 CSP theory 则给出了 constraint scopes、hypergraphs、primal graphs 和 width measures 的  
 成熟数学语言。 <sup>31</sup>

而我们真正的新定义工作是把这些线索连接成：

operational semantics → canonical semantic hypergraph → model-independent structural difficulty vector

并进一步要求它满足三个可证伪标准：

annotation reproducibility  
 representation invariance  
 predictive validity for modeling/feasibility degradation.

其中第三条最终决定这套定义有没有论文价值。现在最合理的研究策略不是继续添加更多 graph metrics，而是  
**冻结这套 v1 ontology 与 metric engine，用 12 个 anchor instances 检查 annotation stability、  
 topological face validity、metric redundancy 和 semantic/algebraic invariance；** 只有通过这一关后，  
 才值得把它扩展为真正的 large-scale operational complexity experiment。

1 5 31 <https://arxiv.org/html/2303.08233v2>  
<https://arxiv.org/html/2303.08233v2>

2 13 22 <https://arxiv.org/abs/0911.0801>  
<https://arxiv.org/abs/0911.0801>

3 8 17 29 <https://arxiv.org/html/2608.02641v1>  
<https://arxiv.org/html/2608.02641v1>

4 12 30 <https://arxiv.org/html/2601.19924v2>  
<https://arxiv.org/html/2601.19924v2>

6 11 14 <https://github.com/optsuite/MIPLIB-NL>  
<https://github.com/optsuite/MIPLIB-NL>

7 <https://arxiv.org/html/2602.10450v2>  
<https://arxiv.org/html/2602.10450v2>

9 <https://github.com/CoraLiang01/lean-llm-opt>  
<https://github.com/CoraLiang01/lean-llm-opt>

10 <https://link.springer.com/article/10.1007/s00453-018-0498-2>  
<https://link.springer.com/article/10.1007/s00453-018-0498-2>

15 24 28 <https://arxiv.org/html/2606.19787>  
<https://arxiv.org/html/2606.19787>

16 <https://arxiv.org/html/2606.04816v1>  
<https://arxiv.org/html/2606.04816v1>

18 <https://epubs.siam.org/doi/10.1137/S0097539793251219>  
<https://epubs.siam.org/doi/10.1137/S0097539793251219>

19 <https://arxiv.org/abs/1207.4109>  
<https://arxiv.org/abs/1207.4109>

20 <https://github.com/PACE-challenge/Treewidth-PACE-2017-instances>  
<https://github.com/PACE-challenge/Treewidth-PACE-2017-instances>

21 <https://pmc.ncbi.nlm.nih.gov/articles/PMC12875492/>  
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12875492/>

23 <https://arxiv.org/html/2507.11080v3>  
<https://arxiv.org/html/2507.11080v3>

25 <https://github.com/Cardinal-Operations/ORLM>  
<https://github.com/Cardinal-Operations/ORLM>

26 <https://arxiv.org/html/2602.15983v1>  
<https://arxiv.org/html/2602.15983v1>

27 <https://arxiv.org/html/2607.16646v1>  
<https://arxiv.org/html/2607.16646v1>