

面向自动优化建模的 Semantic Obligation Hypergraph：规范定义、A/A+ 一致化方案与复杂度计算框架

执行摘要

截至 2026 年 9 月 1 日，我对 NL4OPT、OPT-Engine、ORAgentBench、LEAN-LLM-OPT、MIPLIB-NL、IR2Solve，以及 2026 年 8 月新出现的 OptiDSL、Improving Constraint Models with LLM Agents、AdmitOR 等工作重新进行了交叉检查。核心结论是：

现有文献已经反复接近 “semantic obligation / constraint coupling / structural modeling difficulty” 这一问题，但尚没有发现一项工作把 “自然语言中的业务约束义务” 规范成一个 model-independent、family-level、可计算图指标的 Semantic Obligation Hypergraph。

NL4OPT 最接近 “semantic intermediate representation”，但它面向 LP word problems，将 semantic entity recognition 与 meaning representation 分开；IR2Solve 明确建立了结构化 ModelIR，却为了编译可靠性刻意把有限索引 constraint family 展开成 scalar constraints；MIPLIB-NL 反过来从大型 MIP 中恢复紧凑、可复用结构；OPT-Engine 发现 constraint formulation/constraint augmentation 是 LLM 的主要瓶颈；ORAgentBench 已经显式加入 `constraint_coupling` 维度，但目前公开的 `difficulty.json` 本质上仍是人工给出的 0-3 ordinal rating，而不是可复现的数学定义。¹

2026 年 8 月的新文献进一步强化了我们采用 “双层结构” 的必要性。OptiDSL 显示，同一个问题强制转成 MILP 与使用更自然的 DSL 表示，建模表现可以显著不同；Voboril 与 Szeider 的 constraint-model reformulation 工作显示，同一个问题通过 variable representation、global constraints、symmetry breaking 等变化，solver runtime 可以大幅变化；因此 **semantic problem structure 与 algebraic/formulation structure 不应混为一谈**。² AdmitOR 则特别重要：它用参数重采样做 label-free behavioral validation，但官方 repo 明确承认，因为多个候选共享同一个 extracted specification，**如果 extraction 本身错了，后续 consensus 无法发现该错误**。这正是我们为什么必须把 NL→semantic graph 的定义和自动标注质量控制做好。³

本报告建议正式把我们的对象定义为两个层次：

$$H_S^{all} = (V_S, O_S)$$

表示完整的 semantic obligation inventory；以及从它导出的

$$H_S^c = (V_S, E_S^c), \quad E_S^c = \{o \in O_S : |\text{supp}(o)| \geq 2\}$$

表示真正用于 cross-entity structural coupling 的 coupling hypergraph。

这个区别非常关键。它直接解决了你现在最棘手的 **A → A+ taxonomy instability**：

- 新增一个终端库存下限，应该增加 semantic obligation burden；
- 但它只作用于 `inventory_state` 一个 entity family，因此**不应该凭空增加 entity coupling**；

- day-5 procurement upper-bound 从 76 改成 39，只是现有 upper-bound obligation 的 **parameter override**，不应生成新 obligation；
- one-day lead time 改变的是已有 inventory-balance obligation 的 **temporal incidence pattern**，不应重新制造一类 constraint；
- `first_day_inventory_balance` 与 `interday_inventory_balance` 本来就不应该被 LLM 标成两个 family，它们只是同一个 conservation law 的 boundary case 和 generic case。

因此 A 与 A+ 正确规范化之后应该是：

$$\begin{aligned} A : m_{\text{all}} &= 6, \\ A^+ : m_{\text{all}} &= 7, \end{aligned}$$

但是二者的 cross-entity coupling projection 都只有：

$$\{R, I, U\}, \quad \{I, U\},$$

所以当前静态 coupling metrics 完全相同。这不是 **metric 失败**，而是一个非常重要的研究发现：

constraint quantity、unary rule burden、temporal coupling、exception heterogeneity 与 cross-entity coupling 是不同的 complexity mechanisms，不能用一个 graph-density number 强行混成一个概念。

因此我建议 operational complexity 最终至少采用：

$$\text{OC} = (\mathbf{B}_S, \mathbf{C}_S, \mathbf{C}_F, \mathbf{K}_{\text{comp}})$$

其中：

- $\mathbf{B}_S$ ：semantic obligation burden；
- $\mathbf{C}_S$ ：semantic structural coupling；
- $\mathbf{C}_F$ ：formulation/algebraic coupling；
- $\mathbf{K}_{\text{comp}}$ ：独立的 computational difficulty；
- runtime 是 outcome，不直接进入 intrinsic definition。

下面给出可直接进入我们试水实验的 **SOH-1.1 规范**。

文献与现有表示的边界

现有工作到底“定义到了哪里”

下表非常重要，因为它决定了我们的论文应该如何声明 novelty。“**Semantic Obligation Hypergraph**”应该明确写成我们提出的 **formal construct**，而不能说成已有 OR 文献中的标准术语。CSP 文献有 constraint hypergraph；NL4OPT 有 semantic entity / meaning representation；IR2Solve 有 ModelIR；ORAgentBench 有 constraint coupling；MIPLIB-NL 有 recovered structural model，但这几个概念目前并没有被统一成我们这里的对象。

工作	它实际表示什么	constraint / entity 的颗粒度	coupling / complexity 如何处理	与 SOH 的关系
NL4OPT	NL semantic entities → meaning representation / logical form	偏向文本 mention、LP variable/ objective/ constraint declaration	不定义 graph coupling	最接近“NL semantic normalization”的前驱，但不是 family-level structural graph。竞赛明确把任务拆成 semantic entity recognition 与 meaning representation。 ⁵
IR2Solve	sets、parameters、variables、objective、constraints 的 ModelIR	刻意 scalar 化 ：有限 index constraint family 可展开为 individual entries	目标是防 free-index / implicit quantification errors，不是 intrinsic complexity	极有价值的工程 IR，但它的颗粒度正好与我们相反：我们需要 family-level invariant representation。 ⁶
OPT-Engine	十类 canonical OR tasks + controllable scaling + augmentation	template/ problem-instance level；复杂度随生成规模变化	constraint formulation 被定位为 SIR 的主要瓶颈；constraint augmentation 会显著伤害准确率	强力支持“约束语义困难值得独立研究”，但没有给出 semantic hypergraph 或 coupling 数学定义。 ⁷
ORAgentBench	operational brief + files + solver workflow + hidden validator	end-to-end operational task	六维 difficulty： solving_strategy_requirement, formulation_structure, constraint_coupling, dynamic_structure, data_scale, problem_understanding；repo 中 coupling 为人工 ordinal score	与我们问题最接近，但 constraint_coupling 目前不是可自动复现的 graph metric。 ⁸
LEAN-LLM-OPT	problem description + associated datasets → workflow → formulation	large-scale indexed model/ workflow level	通过 workflow decomposition 与工具减轻 data handling / planning burden	支持把 modeling 和 mechanical data handling 分开，但没有定义 model-independent semantic entity/ obligation graph。 ⁹

工作	它实际表示什么	constraint / entity 的颗粒度	coupling / complexity 如何处理	与 SOH 的关系
MIPLIB-NL	从 MIPLIB solver-level formulation 恢复 compact reusable structure, 再 reverse-generate NL	明显是 constraint-family / indexed structure , 不是百万 scalar rows 的文字复述	关注 industrial scale、structure preservation、NL/model/data alignment	是我们 family-level granularity 最强的现实依据之一；但其结构来自 formal model, 不是纯 NL intrinsic semantic graph。 ¹⁰
OptiDSL	NL $\rightarrow$ domain-appropriate DSL $\rightarrow$ specialized solver	domain-level standardized constructs	representation choice 本身显著影响 formulation accuracy	强力支持 $H_S / H_F \coloneqq$ 同一 problem semantics 可有不同 algebraic representation。 ¹¹
Improving Constraint Models with LLM Agents	已有 CP model $\rightarrow$ alternative equivalent/validated models	solver constraint-model level	variable representation、global constraint、symmetry breaking 等影响 runtime	说明 formulation complexity 与 solver difficulty 不具有 problem-intrinsic invariance。 ¹²
AdmitOR	extracted specification $\rightarrow$ parameter resampling $\rightarrow$ multi-model behavioral agreement	specification/instance behavior level	利用 perturbation 做 label-free certification	非常适合借鉴我们的 annotation validation, 但官方明确说 shared extraction error 无法靠 consensus 发现。 ¹³

CSP 文献给我们什么，不能给我们什么

CSP 的经典结构研究提供了一条非常坚实的数学基础：constraint 可以由其 variable scope 表示，scope 之间的交互形成 hypergraph；treewidth、hypertree width、fractional/generalized hypertree width 等结构参数被用于研究 CSP 可解性和参数化复杂性。Semantic Width 等工作进一步研究了“等价 reformulation 后最优结构宽度”的思想。 ¹⁴

但是必须严格区分：

CSP constraint hypergraph / our semantic obligation hypergraph.

CSP 中的 node 通常是**数学变量**；我们的 V_S 是 **canonical operational entity families**。因此：

我们使用 treewidth、spectral radius 等作为 **structural descriptors / empirical difficulty predictors**，而不是声称“bounded semantic treewidth $\Rightarrow$ LLM polynomial-time solvability”。

这点在论文里必须写清，否则 reviewer 很容易质疑我们把 CSP computational theory 错误搬到了 LLM semantic difficulty 上。

八月新文献对我们最直接的启示

截至 2026 年 9 月 1 日，8 月最值得我们吸收的是这四件事：

IR2Solve: schema-constrained intermediate representation + deterministic verifier/compiler 是现实可行路线，而且它明确把“semantic LLM call”和后面的机械编译分开。我们的 NL→SOH→deterministic metrics pipeline 与它的工程哲学高度兼容。 ⁶

OptiDSL: 同一个 operational problem 被强行写成 MILP 可能产生不必要的 formulation complexity，因此我们不能把 solver algebra 直接定义成 intrinsic operational complexity。 ¹¹

Constraint-model reformulation: formulation choice 会改变 solver behavior，进一步支持 computational/runtime axis 独立。 ¹²

AdmitOR: parameter resampling 可以做很强的 consistency test，但不能替代 semantic gold；因此我们应采用“强 AI 双标 + deterministic checks + 少量 researcher review + perturbation invariance + gold-model solver validation”的组合，而不是相信单次 LLM annotation。 ³

我方规范：双层 SOH 架构

Canonical Semantic Decision Entity 的精确定义

建议正式定义：

Canonical Semantic Decision Entity Family, 简称 CSDE:

一个在 operational problem 中具有独立业务含义的、内生的 action / allocation / flow / state / service quantity family；它的值用于描述一个 operational plan 或 trajectory 是否可行，并且其身份在变量重命名、计量单位变化、参数数值变化、时间跨度扩展及等价数学 formulation 下保持不变。

“Decision Entity”里的 decision 不应狭义理解为“solver primitive decision variable”。例如 inventory level 可能由流量平衡决定，但它仍然是一个重要的 endogenous operational **state**，所以应作为 semantic node。

形式上：

$$V_S = \{v_1, \dots, v_n\}.$$

每一个 v 至少具有：

$$v = (\text{canonical referent}, \text{semantic role}, \text{index signature}, \text{value domain}).$$

例如：

$$R = \text{replenishment_order_quantity}[t],$$

$$I = \text{inventory_state}[t],$$

$$U = \text{unmet_demand}[t].$$

以下内容**不构成** semantic node：

对象	是否进 V_S	理由
demand d_t	否	exogenous parameter
initial inventory I_0	否	initial-condition parameter
tank capacity C	否	exogenous threshold
cost coefficient	否	objective parameter
lead time L	否	temporal relation parameter
<code>x_aux</code> linearization binary	否	formulation artifact
slack/artificial variable	否	solver artifact
deterministic <code>arrival_t = order_{t-L}</code> alias	默认否	如果只是 deterministic shift, 不是独立 operational choice/state
endogenous inventory state	是	operational state
shortage amount	是	endogenous service outcome

Semantic Obligation 的精确定义

建议采用下面这个版本作为论文定义：

Semantic Obligation Family 是一个 **source-grounded、independently falsifiable、parameterized operational rule schema**：它规定可接受的 operational plan/trajectory 必须满足什么条件；它在参数数值、单位、实体命名和 horizon size 改变时保持 family identity，不依赖具体 solver formulation。

关键词是：

independently falsifiable

它给我们一个非常有用的“最小颗粒度”判据：

如果存在一种行为，使 Rule A 被违反，而 Rule B 仍然可以满足，那么 A 和 B 原则上应当是两个 semantic obligations。

例如：

$$6 \leq R_t \leq 35$$

必须拆成：

$$R_t \geq 6, \quad R_t \leq 35,$$

因为二者可以独立违反。

但：

“day 1 balance” 和 “day 2–5 balance” 不能因为数学表达的 boundary form 不同就拆成两个 obligation family。

它们都是：

inventory flow conservation

的不同 index/boundary instantiations。

Hyperedge 必须是 attributed hyperedge

普通 hypergraph 只保存：

$$e = \{R, I, U\}.$$

这对于时间问题不够，因为 inventory balance 实际涉及：

$$I_{t-1}, R_t, I_t, U_t$$

或者 A+ 中：

$$I_{t-1}, R_{t-1}, I_t, U_t.$$

所以我们的 edge 必须同时保存：

$$\text{support}(e) = \{R, I, U\}$$

和更详细的：

$$\text{slots}(e).$$

例如 A：

family	role	temporal binding
I	previous state	$t - 1$
R	usable replenishment	t
I	resulting state	t
U	unmet demand	t

A+：

family	role	temporal binding
I	previous state	$t - 1$
R	usable replenishment	$t - 1$
I	resulting state	t

family	role	temporal binding
U	unmet demand	t

因此 lead time 改变了 temporal semantics, 但没有创造新 node, 也没有创造新 obligation family。

完整 obligation inventory 与 coupling projection

这是目前最重要的一项修改。

定义：

$$H_S^{all} = (V_S, O_S).$$

其中允许 unary obligation：

$$|\text{supp}(o)| = 1.$$

再定义：

$$E_S^c = \{o \in O_S : |\text{supp}(o)| \geq 2\},$$

$$H_S^c = (V_S, E_S^c).$$

这样, “constraint 数量”和 “constraint coupling” 正式分离。

例如：

$$R_t \leq 35$$

是一个真实业务规则, 所以必须进入 O_S ;

但：

$$\text{supp}(o) = \{R\},$$

所以它不产生跨 entity coupling。

这个设计也解决一个此前潜在的数学问题：如果我们把 unary edges 混进 P matrix 的分母, 增加一个纯 terminal bound 反而可能让 normalized spectral coupling 下降。这是显然不符合我们希望测的 “互动结构” 的。

双层结构

正式定义：

$$H_S = (V_S, O_S)$$

为 semantic layer;

$$H_F = (V_F, E_F)$$

为 formulation layer。


其中 V_F 是 solver formulation 中的 variable **families**, E_F 是 constraint **families**。

同时保留映射：

$$\pi_V : V_F \rightarrow V_S \cup \{\text{encoding}\},$$

$$\pi_E : E_F \rightarrow O_S \cup \{\text{encoding}\}.$$

因此：



这样以后可以研究：

$$\mathbf{C}_S \quad \text{vs.} \quad \mathbf{C}_F.$$

排除规则必须细分，不能简单写 “bounds excluded”

这里我要修正一个容易造成严重错误的表述：

不是所有 bounds 都应该排除。

必须区分：

Mathematical domain declaration

例如：

$$x \geq 0, \quad x \in \mathbb{Z}, \quad x \in \{0, 1\}.$$

如果它们只是变量的 mathematical value domain，则：

不作为 semantic obligation edge

而作为 entity attribute：

"value_domain": "continuous_nonnegative"

或

"value_domain": "binary"

Explicit business-rule bound

例如：

supplier permits 6–35 gallons per day

这是真实 operational policy：

$$R_t \geq 6, \quad R_t \leq 35.$$

必须进入 O_S 。

但它们是 unary：

进入 obligation inventory, 不进入 coupling projection

这一区别对于 A/A+ 极其重要。

完整排除/保留规则如下：

内容	H_S^{all}	H_S^c	H_F^{core}
Objective	$\times$ ，单独保存	$\times$	$\times$
Objective coefficients	$\times$	$\times$	$\times$
Pure nonnegativity/domain	$\times$	$\times$	attribute
Explicit business bound	✓	unary 时 $\times$	映射保存
Business capacity	✓	unary 时 $\times$	映射保存
Balance/linking rule	✓	✓	✓
Explicit logical policy	✓	多实体时 ✓	✓
Linearization auxiliary variable	$\times$	$\times$	core 中 $\times$
Linearization constraint	$\times$	$\times$	core 中 $\times$ ，encoding sidecar ✓
Solver cut	$\times$	$\times$	$\times$ /sidecar
Implied redundant algebraic constraint	除非 source-grounded, 否则 $\times$	$\times$	encoding sidecar
Symmetry-breaking constraint	$\times$	$\times$	encoding sidecar

内容	H_S^{all}	H_S^c	H_F^{core}
Parameter/data	parameter table	$\times$	parameter table

这与 8 月 constraint-model reformulation 的发现正好吻合：symmetry breaking、implied constraints、global-constraint representation 等可以改变 solver performance，却不意味着 underlying operational problem 本身发生改变。 ¹²

A 与 A+ 的规范化 gold

你给的两个现有 LLM 输出清楚暴露了 taxonomy drift。A 的输出把 balance 拆成 first_day_stock_balance 和 interday_stock_balance，并产生了 shortage_only_when_stock_exhausted 与 unmet_consumption_is_not_recoverable；A+ 的输出则又换成 initial_day_inventory_balance、lagged_daily_inventory_balance，遗漏了前述两个 lost-sales rules，并新增了一个 shortage_cannot_exceed_daily_consumption。

这说明现在的 prompt 允许 LLM 边理解题目、边自由发明 taxonomy。这是不可接受的，因为我们的 complexity metrics 会因此测到“LLM annotation style”，而不是 problem complexity。

A 与 A+ 的统一 canonical nodes

两个问题都只有三个 family-level semantic entities：

Canonical ID	Canonical name	类型	indices	A 表述	A+ 表述
R	replenishment_order_quantity	action / inflow decision	day/ order_day	shipment volume	procurement volume
I	inventory_state	state	day	ending stock	physically held stock
U	unmet_demand	service outcome	day	deficit / unmet consumption	shortage / unmet consumption

因此：

$$n = 3$$

对 A、A+ 都不变。

“shipment” 和 “procurement” 不应该因为英文词不同成为不同 ontology concepts。

单位 gallon 与 liter 同样不能改变 entity identity：

$$\text{physical dimension} = \text{volume}.$$

A 的人工 gold semantic obligations

记：

$$T = \{1, \dots, 5\}.$$

A 的参数来自题面： $I_0 = 42$ 、 $d_t = (49, 17, 41, 47, 50)$ 、 $R^{min} = 6$ 、 $R^{max} = 35$ 、 $C = 55$ 、lead time $L = 0$ 。成本参数只属于 objective metadata。

ID	canonical family	structural label	support	normalized semantic obligation	参数来源
A-O1	replenishment_lower_bound	LOWER_BOUND / action_limit	$\{R\}$	$\forall t, R_t \geq 6$	“between 6 and 35 gallons”
A-O2	replenishment_upper_bound	UPPER_BOUND / action_limit	$\{R\}$	$\forall t, R_t \leq 35$	同上
A-O3	inventory_flow_balance	BALANCE / conservation	$\{R, I, U\}$	prior inventory + immediately available replenishment must reconcile consumption, resulting stock and unmet demand	initial stock、daily demand、instant delivery
A-O4	inventory_capacity	UPPER_BOUND / state_capacity	$\{I\}$	$\forall t, I_t \leq 55$ at end of day	tank capacity 55
A-O5	shortage_requires_stock_exhaustion	IMPLICATION / service_semantics	$\{I, U\}$	$U_t > 0 \Rightarrow I_t = 0$ for usable physical inventory	stock-out / unsatisfied-consumption semantics
A-O6	lost_sales_no_backlog	NO_CARRYOVER / service_semantics	$\{U\}$	unmet demand at t is lost and is not transferred into future-period demand	“lost and cannot be recovered later”

注意：

first-day balance + interday balance → ONE family

A 的原 LLM 输出将其拆成 o3/o4，是 family-level normalization 错误。filecite[turn0file0]

generic balance 可以表示成：

$$I_t = I_{t-1} + R_t - d_t + U_t,$$

其中 I_0 是参数，因此 day 1 只是：

$$t = 1$$

的 boundary instantiation，而不是新 obligation。

所以：

$$m_{\text{all}}(A) = 6.$$

incidence count：

$$I_{\text{all}} = 1 + 1 + 3 + 1 + 2 + 1 = 9.$$

因此：

$$\bar{a}_{\text{all}} = \frac{9}{6} = 1.5.$$

A+ 的人工 gold semantic obligations

A+ 的 canonical nodes 完全不变。

参数变为：

$$\begin{aligned} I_0 &= 11, \quad L = 1, \\ d &= (49, 52, 26, 40, 14), \\ R_t^{\min} &= 4, \\ R_t^{\max} &= (76, 76, 76, 76, 39), \\ C &= 48, \quad I_5^{\min} = 15. \end{aligned}$$

Gold obligations：

ID	canonical family	structural label	support	normalized semantic obligation	参数来源
A+-O1	replenishment_lower_bound	LOWER_BOUND / action_limit	{R}	$\forall t, R_t \geq 4$	daily request ≥ 4

ID	canonical family	structural label	support	normalized semantic obligation	参数来源
A+-O2	replenishment_upper_bound	UPPER_BOUND / action_limit	$\{R\}$	$R_t \leq R_t^{max}$, with $R_5^{max} = 39$	normal upper 76 + day-5 override
A+-O3	inventory_flow_balance	BALANCE / conservation	$\{R, I, U\}$	prior inventory and the order arriving after one-day delay reconcile current demand, stock and shortage	initial stock、demand、lead time 1
A+-O4	inventory_capacity	UPPER_BOUND / state_capacity	$\{I\}$	physical inventory ≤ 48 at applicable measurement phases	tank capacity 48
A+-O5	shortage_requires_stock_exhaustion	IMPLICATION / service_semantics	$\{I, U\}$	positive unmet demand requires exhaustion of usable inventory	same stock-out semantics
A+-O6	lost_sales_no_backlog	NO_CARRYOVER / service_semantics	$\{U\}$	unmet demand does not propagate to future periods	“lost and cannot be deferred”
A+-O7	terminal_inventory_minimum	LOWER_BOUND / terminal_condition	$\{I\}$	day-5 physical inventory must be at least 15	explicit final-day rule

因此：

$$m_{\text{all}}(A^+) = 7,$$

$$I_{\text{all}}(A^+) = 1 + 1 + 3 + 1 + 2 + 1 + 1 = 10,$$

$$\bar{a}_{\text{all}}(A^+) = \frac{10}{7} \approx 1.4286.$$

为什么 day-5 upper bound 不是新 obligation

A+ 中:

normal upper limit = 76

day 5 upper limit = 39

应被规范成一个 parameterized family:

$$R_t \leq U_t,$$

其中:

$$U_t = \begin{cases} 76, & t = 1, \dots, 4, \\ 39, & t = 5. \end{cases}$$

所以:

parameter override /

= new obligation family

这是我们解决 augmentation taxonomy instability 的第一条核心原则。

为什么 final-day inventory minimum 是新 obligation

此前不存在:

$$I_t \geq L_t$$

这一类 inventory lower-bound policy。

新增:

$$I_5 \geq 15$$

因此不是对已有 family 的参数修改, 而是引入新的 admissibility predicate。

所以:

new predicate $\Rightarrow$ new obligation
--

为什么 lead time 不创造新 obligation

A:

$$R_t \rightarrow \text{available at } t.$$

A+:

$$R_t \rightarrow \text{available at } t + 1.$$

因此 A+ 的 generic balance 可写为：

$$I_t = I_{t-1} + R_{t-1} - d_t + U_t, \quad t \geq 2.$$

本质仍然是：

$$\text{inventory_flow_balance}$$

变化的只是 incidence slot：

$$\delta_R : 0 \rightarrow -1.$$

因此 temporal binding 必须作为 edge attribute，而不能靠创建新的 taxonomy label 表达。

为什么 **shortage_cannot_exceed_daily_consumption** 不应单独成为 primary obligation

A+ 的原 LLM 输出新增：

$$U_t \leq d_t.$$

filecite turn0 file1

它不是题面新增的一条独立 business policy，而是 **unmet_demand** 这个 entity 被定义为“当前 demand 中未满足部分”之后的 **derived semantic consequence**。

因此建议放入：

```
"derived_checks": [
  {
    "predicate": "unmet_demand[t] <= demand[t]",
    "derived_from": ["entity_semantics:unmet_demand"]
  }
]
```

而不进入 primary O_S 。

否则不同 LLM 有的会展开所有逻辑推论、有的只记录显式业务规则， m 会完全不可比较。

最小可分辨单元与合并优先级

正式建议使用以下判定顺序：

最高优先级：operational predicate identity。

不是看英语 label 是否相似，而是问：

它限制的是不是同一种 operational behavior？

然后依次检查：

predicate → entity roles → index schema → temporal roles → parameters.

参数差异最低优先级。

具体规则：

情形	操作
同 predicate, 仅参数值变化	MERGE
同 predicate, 仅单位变化	MERGE
同 predicate, horizon 5→10	MERGE
同 predicate, 某 period threshold override	MERGE, 写入 parameter schedule
同 conservation law, initial boundary expression 不同	MERGE, 写入 boundary variant
lead time 数值变化	MERGE family, 更新 temporal slots
新 terminal condition	SPLIT / new obligation
一个 range 包含 lower + upper	SPLIT
两个规则可独立违反	默认 SPLIT
algebraically implied consequence	放 <code>derived_checks</code>
solver reformulation artifact	排除 semantic layer

对于自动 dedup, 可以设置一个**硬结构 gate + 软语义阈值**：

$$G_{\text{hard}} = \begin{cases} 1, & \text{predicate compatible} \\ & \wedge \text{support roles compatible} \\ & \wedge \text{index domain compatible} \\ 0, & \text{otherwise.} \end{cases}$$

只有 $G_{\text{hard}} = 1$ 才允许 embedding/LLM similarity 介入。

建议 pilot 初值：

$$\begin{aligned} s_{\text{semantic}} \geq 0.92 &\Rightarrow \text{auto merge,} \\ 0.85 \leq s < 0.92 &\Rightarrow \text{second-model adjudication,} \\ s < 0.85 &\Rightarrow \text{keep separate.} \end{aligned}$$

这些数值**不是理论常数**，只是 SOH pilot 的初始工程阈值，后续应通过 12 anchor + perturbation suite 校准。

强 AI 自动标注协议

最重要的 prompt 原则

我们不能让强模型回答：

“请列出这个问题的 constraints。”

因为这样它一定会按照自己的数学建模习惯决定颗粒度。

Prompt 应该告诉它：

你的任务不是 formulation，而是 semantic normalization。不要生成 solver code，不要决定采用 LP/MILP/CP，也不要自由创建 taxonomy。

建议 production pipeline 使用：

NL → atomic semantic extraction → canonical normalization → deterministic validation.

IR2Solve 已证明 “semantic LLM step + deterministic verifier/compiler” 是可行的工程范式；我们的区别只是 LLM 输出对象从 solver IR 前移到了 model-independent semantic IR。 6

高精度 prompt 模板

下面这个版本可以直接作为 SOH-1.1 annotator system prompt 的基础。

ROLE

You are a Semantic Optimization Annotation Engine.

Your task is NOT to formulate a mathematical optimization model,
NOT to write solver code, and NOT to choose an algorithm.

Your task is to convert a natural-language operational optimization
problem into a canonical, model-independent semantic representation.

=====

CORE DEFINITIONS

=====

1. CANONICAL SEMANTIC DECISION ENTITY FAMILY

A canonical semantic decision entity family is an endogenous
operational action, allocation, flow, state, selection, schedule,
or service-outcome quantity needed to describe a feasible operational
plan.

Entity identity MUST be invariant to:

- variable names,
- synonyms,
- physical units,

- numerical parameter values,
- horizon length,
- algebraic formulation,
- solver choice.

Examples:

"shipment quantity", "procurement amount", "replenishment volume"
may refer to the same canonical operational family:
replenishment_order_quantity.

DO NOT create entity nodes for:

- exogenous demand,
- capacities,
- costs,
- initial conditions,
- lead times,
- objective coefficients,
- pure constants,
- deterministic aliases,
- slack variables,
- artificial variables,
- linearization auxiliary variables.

Store these as parameters or formulation metadata instead.

2. SEMANTIC OBLIGATION FAMILY

A semantic obligation family is a source-grounded,
independently falsifiable, parameterized operational rule schema
that restricts the admissible operational plans or trajectories.

An obligation family MUST remain the same when only:

- parameter values change,
- measurement units change,
- horizon length changes,
- entity names change,
- a threshold becomes period-dependent,
- a boundary instantiation differs from generic periods.

3. MINIMUM GRANULARITY RULE

Split two clauses into separate obligations if they can be
independently violated.

Example:

"6 <= order_t <= 35"

MUST become:

- (a) replenishment_lower_bound
- (b) replenishment_upper_bound

4. FAMILY MERGING RULE

DO NOT split one family merely because:

- day 1 has an initial-condition expression,
- later days use a recurrence,
- a parameter differs on day 5,
- a lead time changes an index offset,
- the same rule is stated using different synonyms.

Represent these differences through:

- parameters,
- parameter_overrides,
- boundary_variants,
- temporal incidence slots.

5. DERIVED CONSEQUENCE RULE

Do NOT add every algebraic or logical implication as a primary semantic obligation.

Example:

If "unmet demand" is explicitly defined as the unsatisfied part of current demand, then

`unmet_demand[t] <= demand[t]`

may be stored as a `derived_check`, but is not automatically a new business-rule obligation.

6. OBJECTIVE RULE

Store the objective separately.

The objective NEVER becomes a feasibility/coupling hyperedge.

7. BOUNDS RULE

Pure mathematical domains such as:

`x >= 0`, `x binary`, `x integer`

are entity-domain attributes, not semantic obligations, unless the natural-language problem explicitly states them as business policies.

Explicit operational limits such as:

"orders must be between 6 and 35"

ARE semantic obligations.

8. TEMPORAL RULE

A lead time does not create a new entity if arrival is a deterministic time shift of an existing order.

Record temporal roles with relative offsets.

Example:

order placed at t and available at t+1:
entity = replenishment_order_quantity
slot temporal_offset = -1
when the obligation is indexed by receiving period t.

9. COUPLING

Do NOT decide graph metrics.
Output support entities and incidence slots only.
The deterministic downstream program will compute coupling.

10. EVIDENCE

Every entity and obligation must contain exact source_spans supporting the annotation.

Do not output hidden reasoning or chain-of-thought.

Output only:

- normalized semantic statement,
- concise normalization rationale,
- source evidence,
- structured confidence values.

FEW-SHOT NORMALIZATION EXAMPLES

Example A

Input:

"Each day the order must be between 6 and 35 units."

Correct:

Two obligation families:

- replenishment_lower_bound
- replenishment_upper_bound

Incorrect:

One generic "order range constraint".

Example B

Input:

"Orders may be at most 76 units per day.
On day 5 the maximum is 39."

Correct:

ONE obligation family:

replenishment_upper_bound

with parameter schedule:

upper_bound[t] = [76, 76, 76, 76, 39]

Incorrect:

- regular_maximum_order
- day5_maximum_order

Example C

Input:

"Initial inventory is 10.

For subsequent periods, inventory carries over."

Correct:

ONE inventory_flow_balance family with a boundary variant.

Incorrect:

- first_day_balance
- later_day_balance

Example D

Input:

"An order requires one day before becoming available."

Correct:

Modify the temporal slot of replenishment inside the existing inventory_flow_balance obligation.

Incorrect:

Create a new "lead_time_constraint" hyperedge unless the statement imposes an independently falsifiable operational rule beyond the timing relationship itself.

=====

FINAL SELF-CHECK

=====

Before returning JSON verify:

- synonyms are canonicalized;
- no parameter is an entity;
- objective is excluded from obligations;
- lower and upper business bounds are separate;
- period-specific threshold overrides are merged;
- boundary cases are not separate families;
- derived consequences are not promoted to primary obligations;
- every obligation has evidence;
- every referenced entity/parameter exists;
- temporal offsets are explicit;
- no solver-specific artifact appears in the semantic graph.

输出 JSON-Schema

建议 SOH-1.1 采用以下核心 schema。这里故意把 `support_entity_ids` 和 `incidence_slots` 分开，因为普通 hyperedge support 无法保留 I_{t-1} 与 I_t 的重复 incidence。

```

{
  "$schema": "https://json-schema.org/draft/2020-12/schema",
  "title": "Semantic Obligation Hypergraph SOH-1.1",
  "type": "object",
  "required": [
    "schema_version",
    "instance_id",
    "sets",
    "parameters",
    "entities",
    "objective",
    "obligations",
    "derived_checks"
  ],
  "properties": {
    "schema_version": {
      "const": "SOH-1.1"
    },
    "instance_id": {
      "type": "string"
    },
    "sets": {
      "type": "array",
      "items": { "$ref": "#/$defs/set" }
    },
    "parameters": {
      "type": "array",
      "items": { "$ref": "#/$defs/parameter" }
    },
    "entities": {
      "type": "array",
      "items": { "$ref": "#/$defs/entity" }
    },
    "objective": {
      "$ref": "#/$defs/objective"
    },
    "obligations": {
      "type": "array",
      "items": { "$ref": "#/$defs/obligation" }
    },
    "derived_checks": {
      "type": "array",
      "items": { "$ref": "#/$defs/derivedCheck" }
    },
    "annotation_warnings": {
      "type": "array",
      "items": { "type": "string" }
    }
  },
  "$defs": {

```

```

"set": {
  "type": "object",
  "required": ["id", "semantic_role"],
  "properties": {
    "id": { "type": "string" },
    "semantic_role": { "type": "string" },
    "values": {}
  }
},

"parameter": {
  "type": "object",
  "required": [
    "id",
    "semantic_role",
    "indices",
    "source_mode"
  ],
  "properties": {
    "id": { "type": "string" },
    "semantic_role": { "type": "string" },
    "indices": {
      "type": "array",
      "items": { "type": "string" }
    },
    "physical_dimension": { "type": ["string", "null"] },
    "unit": { "type": ["string", "null"] },
    "values": {},
    "source_mode": {
      "enum": ["inline", "external_data_ref"]
    },
    "data_ref": {
      "type": ["string", "null"]
    },
    "source_spans": {
      "type": "array",
      "items": { "type": "string" }
    }
  }
},

"entity": {
  "type": "object",
  "required": [
    "id",
    "canonical_name",
    "semantic_type",
    "index_signature",
    "value_domain",
    "source_spans",
    "confidence"
  ]
}

```



```

],
"properties": {
  "id": { "type": "string" },
  "canonical_name": { "type": "string" },
  "semantic_type": {
    "enum": [
      "action",
      "allocation",
      "flow",
      "state",
      "selection",
      "schedule",
      "service_outcome",
      "other_endogenous"
    ]
  },
},
"index_signature": {
  "type": "array",
  "items": {
    "type": "object",
    "required": ["role", "set_id"],
    "properties": {
      "role": { "type": "string" },
      "set_id": { "type": "string" }
    }
  }
},
"value_domain": {
  "enum": [
    "continuous",
    "continuous_nonnegative",
    "integer",
    "integer_nonnegative",
    "binary",
    "other"
  ]
},
"physical_dimension": {
  "type": ["string", "null"]
},
"source_spans": {
  "type": "array",
  "minItems": 1,
  "items": { "type": "string" }
},
"confidence": {
  "$ref": "#/$defs/confidence"
}
},

```

```

"objective": {
  "type": "object",
  "required": [
    "sense",
    "normalized_semantics",
    "excluded_from_feasibility_hypergraph"
  ],
  "properties": {
    "sense": {
      "enum": ["minimize", "maximize", "feasibility"]
    },
    "normalized_semantics": { "type": "string" },
    "entity_scope": {
      "type": "array",
      "items": { "type": "string" }
    },
    "parameter_refs": {
      "type": "array",
      "items": { "type": "string" }
    },
    "excluded_from_feasibility_hypergraph": {
      "const": true
    }
  }
},

"obligation": {
  "type": "object",
  "required": [
    "id",
    "canonical_family",
    "structural_form",
    "business_role",
    "normalized_semantics",
    "support_entity_ids",
    "incidence_slots",
    "quantifier",
    "scope_kind",
    "parameter_refs",
    "source_grounding",
    "source_spans",
    "confidence"
  ],
  "properties": {
    "id": { "type": "string" },
    "canonical_family": { "type": "string" },

    "structural_form": {
      "enum": [
        "LOWER_BOUND",
        "UPPER_BOUND",

```

```

    "BALANCE",
    "EQUALITY",
    "INEQUALITY",
    "IMPLICATION",
    "NO_CARRYOVER",
    "ASSIGNMENT",
    "COVERAGE",
    "PRECEDENCE",
    "CARDINALITY",
    "ACTIVATION_LINK",
    "AGGREGATE_LIMIT",
    "OTHER_RELATION"
  ]
},

"business_role": { "type": "string" },

"normalized_semantics": {
  "type": "string"
},

"support_entity_ids": {
  "type": "array",
  "minItems": 1,
  "uniqueItems": true,
  "items": { "type": "string" }
},

"incidence_slots": {
  "type": "array",
  "minItems": 1,
  "items": {
    "$ref": "#/$defs/incidenceSlot"
  }
},

"quantifier": {
  "type": "string"
},

"scope_kind": {
  "enum": [
    "universal",
    "subset",
    "boundary",
    "terminal",
    "conditional"
  ]
},

"parameter_refs": {

```

```

    "type": "array",
    "items": { "type": "string" }
  },

  "parameter_overrides": {
    "type": "array",
    "items": {
      "type": "object",
      "properties": {
        "scope": { "type": "string" },
        "parameter_id": { "type": "string" },
        "value": {}
      }
    }
  },

  "boundary_variants": {
    "type": "array",
    "items": {
      "type": "object",
      "properties": {
        "scope": { "type": "string" },
        "description": { "type": "string" }
      }
    }
  },

  "source_grounding": {
    "enum": [
      "explicit",
      "definitional_entailment"
    ]
  },

  "source_spans": {
    "type": "array",
    "minItems": 1,
    "items": { "type": "string" }
  },

  "normalization_rationale": {
    "type": "string"
  },

  "confidence": {
    "$ref": "#/$defs/confidence"
  }
},

"incidenceSlot": {

```

```

"type": "object",
"required": [
  "entity_id",
  "semantic_role",
  "index_bindings"
],
"properties": {
  "entity_id": { "type": "string" },
  "semantic_role": { "type": "string" },
  "index_bindings": {
    "type": "object"
  },
  "temporal_offset": {
    "type": ["integer", "null"]
  }
}
},

```

```

"confidence": {
  "type": "object",
  "required": [
    "source_grounding",
    "canonicalization",
    "support_mapping",
    "temporal_binding"
  ],
  "properties": {
    "source_grounding": {
      "type": "number",
      "minimum": 0,
      "maximum": 1
    },
    "canonicalization": {
      "type": "number",
      "minimum": 0,
      "maximum": 1
    },
    "support_mapping": {
      "type": "number",
      "minimum": 0,
      "maximum": 1
    },
    "temporal_binding": {
      "type": "number",
      "minimum": 0,
      "maximum": 1
    }
  }
},

```

```

"derivedCheck": {

```

```

    "type": "object",
    "required": ["predicate", "derived_from"],
    "properties": {
      "predicate": {"type": "string"},
      "derived_from": {
        "type": "array",
        "items": {"type": "string"}
      }
    }
  }
}
}
}

```

不要过分相信 LLM 自己报的 confidence

LLM 自报：

0.97

不能理解成 calibrated probability。

真正有用的是把 confidence 拆成四项：

$$(c_{\text{source}}, c_{\text{canon}}, c_{\text{support}}, c_{\text{temporal}})$$

然后 downstream 采用：

$$c_o^{\min} = \min(c_{\text{source}}, c_{\text{canon}}, c_{\text{support}}, c_{\text{temporal}}).$$

例如：

$$c_o^{\min} < 0.85$$

自动进入第二个强模型的 adjudication。

最终可靠度主要来自：

model agreement + invariance tests + gold-model checks,


而不是 LLM 自信程度。AdmitOR 对 shared-specification failure 的公开限制尤其说明了这一点。

13

自动计算与数值示例

从 AI 输出到标准 hypergraph 的 deterministic pipeline

建议把 LLM 的作用严格停在 semantic annotation；从 JSON 开始全部 deterministic：



核心 pseudocode:

```

def build_semantic_hypergraph(annotation):
    validate_json_schema(annotation)

    entities = canonicalize_entities(annotation["entities"])
    obligations = []

    for raw in annotation["obligations"]:
        assert_sources_exist(raw)
        assert_entity_refs_exist(raw, entities)

        rule = normalize_predicate(raw)
        rule = normalize_units(rule)
        rule = normalize_index_roles(rule)

        if is_derived_only(rule):
            move_to_derived_checks(rule)
            continue

        obligations.append(rule)

    obligations = merge_parameter_variants(obligations)
    obligations = merge_boundary_variants(obligations)
    obligations = merge_horizon_instantiations(obligations)
  
```

```

# A range is split before this stage into lower/upper predicates.
assert_atomic_obligations(obligations)

H_all = Hypergraph(
    nodes=entities,
    edges=obligations
)

E_c = [
    edge for edge in obligations
    if len(set(edge.support_entity_ids)) >= 2
]

H_c = Hypergraph(
    nodes=entities,
    edges=E_c
)

return H_all, H_c

```

基本 family-level quantities

对 coupling projection:

$$H^c = (V, E),$$

令:

$$n = |V|, \quad m = |E|,$$

$$I = \sum_{e \in E} |e|,$$

$$\bar{a} = \frac{I}{m}.$$

其中 I 是 incidence count, $\bar{a}$ 是平均 relational arity。

但同时必须单独保存:

$$m_{\text{all}} = |O_S|$$

以及:

$$I_{\text{all}} = \sum_{o \in O_S} |\text{supp}(o)|.$$

否则 terminal/unary obligations 会彻底消失。

Incidence density

定义:

$$D_I = \frac{I}{nm}$$

它描述每一个 obligation-family $\times$ entity-family possible incidence 中实际被占据的比例。

注意必须在 H^c 上算。

如果用 full obligation graph 算，A+ 增加一个 unary terminal rule 后：

$$D_I$$

可能下降。这说明它不能同时承担 “rule count” 和 “coupling” 的意义。

Constraint-intersection density

令：

$$N_{\cap} = |\{(i, j) : i < j, e_i \cap e_j \neq \emptyset\}|.$$

则：

$$D_{\cap} = \frac{N_{\cap}}{\binom{m}{2}}$$

表示 constraint families 中有多少 pair 至少共享一个 semantic entity。

若 $m < 2$ ，建议返回 `null`，不要人为填 0。

Conditional mean overlap

只在相交 edge pairs 上求 Jaccard：

$$J_+ = \frac{1}{N_{\cap}} \sum_{e_i \cap e_j \neq \emptyset} \frac{|e_i \cap e_j|}{|e_i \cup e_j|}$$

这样可以分离：

- 有没有 interaction： $D_{\cap}$
- interaction 发生时共享得有多深： J_+

而不是把两件事塞进一个 all-pairs mean overlap。

Weighted primal matrix

定义：

$$P_{uv} = \frac{1}{m} \sum_{e \in E} \mathbf{1}\{u \in e, v \in e\}, \quad u \neq v, \quad =$$

且：

$$P_{uu} = 0.$$

它表示两个 entity families 被多少比例的 relational obligations 同时涉及。

Normalized spectral coupling

令：

$$\lambda_{\max}(P)$$

为 P 最大特征值。

我们提出：

$$C_{\text{spec}} = \frac{\lambda_{\max}(P)}{n-1}$$

因为：

$$0 \leq P_{uv} \leq 1,$$

所以该 normalization 给我们一个方便比较的：

$$0 \leq C_{\text{spec}} \leq 1.$$

这里必须在论文中明确：

这是**我们提出的 normalized semantic coupling statistic**，不是文献中已有标准 OR complexity measure。

Treewidth-like global interaction

从 P 构造 simple primal graph：

$$G_P = (V, E_P),$$

其中：

$$(u, v) \in E_P \iff P_{uv} > 0.$$

计算：

$$tw(G_P).$$

归一化：

$$C_{\text{tw}} = \frac{tw(G_P)}{n-1}$$

CSP 文献正是因为 constraint scopes 形成的结构宽度会影响 decomposability/tractability，才使 treewidth 类参数成为很自然的理论参考；但这里我们只把它当 semantic interaction topology 的 descriptor。 14

对于 pilot 中很小的 family graph:

$$n \lesssim 20-30$$

可以尝试 exact 或 branch-and-bound。

对于大型 graph，不应该伪装成 exact:

$$tw_{LB} \leq tw(G) \leq tw_{UB}$$

输出:

```
{
  "treewidth_exact": null,
  "treewidth_lower_bound": 8,
  "treewidth_upper_bound": 11,
  "treewidth_status": "bounded"
}
```

其中 upper bound 可由 min-fill/min-degree decomposition 得到; lower bound 可采用 clique/minor-based heuristic。正式实验必须固定算法和版本，保证不同 benchmark 可复现。

Hubness

在 simple primal graph G 上:

$$d_v = \deg(v), \quad d_{\max} = \max_v d_v.$$

Freeman-style degree centralization:

$$C_{\text{hub}} = \frac{\sum_v (d_{\max} - d_v)}{(n-1)(n-2)}$$

当 $n \leq 2$ 定义为 0。

它能区分:

- star: 高 hubness;
- clique: hubness 低;
- cycle: hubness 低。

因此 hubness 并不是“更多 coupling”，而是 **coupling shape**。

Cycle rank

对 primal graph:

$$\mu = |E_P| - |V| + c$$

其中 c 是 connected-component 数量。

对于 connected graph:

$$\mu = |E_P| - |V| + 1.$$

它表示独立 graph cycles 的数量。

LCC proportion

令最大连通分量为 V_{LCC} :

$$C_{LCC} = \frac{|V_{LCC}|}{n}$$

它能区分一个高度集中整体系统和多个相互独立的 operational modules。

A 与 A+ 的 coupling projection

A:

$$O_S = \{O_1, O_2, O_3, O_4, O_5, O_6\}.$$

其中真正 multi-entity 的只有:

$$e_1 = \{R, I, U\}$$

即 inventory balance, 以及:

$$e_2 = \{I, U\}$$

即 shortage-inventory exhaustion semantics。

因此:

$$H_A^c = (\{R, I, U\}, \{\{R, I, U\}, \{I, U\}\}).$$

A+ 虽然多了 terminal requirement, 但它是:

$$\{I\},$$

所以:

$$H_{A^+}^c = H_A^c$$

在 static family-level topology 意义上成立。

A/A+ 的完整数值计算

节点:

$$n = 3.$$

coupling edges:

$$m = 2.$$

incidences:

$$I = 3 + 2 = 5.$$

所以:

$$\bar{a} = \frac{5}{2} = 2.5.$$

Incidence density:

$$D_I = \frac{5}{3 \times 2} = \boxed{0.8333}.$$

两个 edge 相交:

$$e_1 \cap e_2 = \{I, U\}.$$

因此:

$$D_{\cap} = \boxed{1}.$$

Jaccard:

$$\frac{|e_1 \cap e_2|}{|e_1 \cup e_2|} = \frac{2}{3}.$$

所以:

$$J_+ = \boxed{0.6667}.$$

按顺序:

$$(R, I, U)$$

得到:

$$P = \begin{pmatrix} 0 & 0.5 & 0.5 \\ 0.5 & 0 & 1 \\ 0.5 & 1 & 0 \end{pmatrix}.$$

其最大特征值为:

$$\lambda_{\max} = 1.3660254 = \frac{1 + \sqrt{3}}{2}.$$

因此:

$$C_{\text{spec}} = \frac{1.3660254}{2} = \boxed{0.6830}.$$

由于 $\{R, I, U\}$ 这一 hyperedge 在 primal graph 中直接产生：

$$R - I, \quad R - U, \quad I - U,$$

所以：

$$G_P = K_3.$$

于是：

$$tw(K_3) = 2,$$

$$C_{tw} = \frac{2}{3-1} = \boxed{1}.$$

三个 node degree 都为 2：

$$C_{hub} = \boxed{0}.$$

cycle rank：

$$\mu = 3 - 3 + 1 = \boxed{1}.$$

所有节点都在一个 component：

$$C_{LCC} = \boxed{1}.$$

A/A+ 结果表

Metric	A	A+	含义
n	3	3	semantic entity families
m_{all}	6	7	A+ 多一个真正的新 semantic rule
I_{all}	9	10	full semantic incidence
$\bar{a}_{all}$	1.500	1.429	unary rule 增加导致下降
m_c	2	2	relational/coupling obligations
I_c	5	5	relational incidences
$\bar{a}_c$	2.500	2.500	relational arity
D_I	0.833	0.833	static family incidence density
$D_{\cap}$	1.000	1.000	两 relational rules 相交
J_+	0.667	0.667	overlap depth
C_{spec}	0.683	0.683	global weighted interaction
C_{tw}	1.000	1.000	K3 topology
C_{hub}	0	0	无 hub-dominated shape

Metric	A	A+	含义
μ	1	1	一个 independent cycle
LCC ratio	1	1	全部 connected
decision→availability lag	0	1	A+ 新增 temporal difficulty
threshold exception count	0	1	A+ 有 day-5 upper override

简单条形图

Semantic obligation burden



Cross-entity coupling edges



Normalized spectral coupling



Decision-to-availability lead time



这张非常简单的图其实给出了一个很重要的论文结论雏形：

A+ 比 A 多了 semantic burden、temporal lag 和 parameter exception，但并没有增加 static cross-entity coupling。

所以：

$$\text{constraint coupling} /$$

= constraint complexity

更准确地说：

semantic modeling difficulty = $f(\text{obligation burden, cross-entity coupling, temporal dependency, exception structure})$

这正说明我们最初坚持 **vector-first** 是正确的。

建议增加一个 semantic burden sidecar

当前 requested topology vector:

$$\mathbf{C}_S = (D_I, D_{\cap}, J_+, C_{\text{spec}}, C_{\text{tw}}, C_{\text{hub}}, \mu, C_{\text{LCC}})$$

之外，我现在强烈建议至少同步记录：

$$\mathbf{B}_S = (m_{\text{all}}, m_{\text{unary}}, m_{\text{rel}}, N_{\text{exception}}, L_{\text{decision}}, N_{\text{conditional}})$$

A:

$$\mathbf{B}_A = (6, 4, 2, 0, 0, \dots),$$

A+:

$$\mathbf{B}_{A+} = (7, 5, 2, 1, 1, \dots).$$

不要现在把它们聚合成 scalar。

先检验每个 axis 对 LLM failure 的预测能力。

Continuous / integer 与 family aggregation

A 和 A+ 都是 continuous:

```
"value_domain": "continuous_nonnegative"
```

但如果另一个 benchmark 把 replenishment 规定成 integer:

$$R_t \in \mathbb{Z}_+,$$

我们不会因为 integrality 把 `replenishment_order_quantity` 换成另一个 semantic entity family。

因此:

$$V_S$$

不变;

integrality 是 node attribute。

原因是:

semantic node identity 表示 “做什么 operational decision”，而不是 “solver 如何表示这个 decision”。

但是 integrality 可能显著改变:

$$\mathbf{K}_{\text{comp}},$$

即 computational difficulty。

因此 continuous/discrete 应成为 semantic metadata + computational axis，而不是 static coupling graph topology。

同样：

42 gallons

与：

11 liters

都应归一为：

```
"physical_dimension": "volume"
```

单位不能影响 graph。

大型 external data 怎么处理

虽然我们当前可以先假设参数直接写在题面，但 schema 最好现在就预留：

```
"source_mode": "external_data_ref",  
"data_ref": "demand.csv::daily_demand"
```

这对 MIPLIB-NL 和 LEAN-LLM-OPT 很快就会需要，因为 MIPLIB-NL 本身采用 problem-data separation，每个实例同时提供自然语言 specification、formal model 和 raw data references；LEAN-LLM-OPT 的输入也明确包括 problem description 与 associated datasets。 ¹⁵

关键是：

coupling graph 通常不需要读取全部 numeric cells。

我们只需要知道：

$$d_{ijt}$$

是什么 parameter family、有哪些 semantic indices、被哪些 obligations 引用。

因此未来即使一个 CSV 有一百万行，也不应该让 AI 把一百万个 parameter values 塞进 annotation prompt。只读取 schema/metadata 和必要 slices 即可。

标注验证与试水实验计划

没有大规模专家 annotation 时的推荐体系

在我们当前实验条件下，最现实的方案不是“一个超强模型充当专家”，而是：

四层。

特别是 AdmitOR 已经给出了一个重要警告：多模型在同一个错误 extracted specification 上达成一致，并不意味着它们理解了原始 intent。 ¹³

独立双标而不是单模型 self-review

对每个 instance：

$A_1 = \text{Annotator Model A,}$

$A_2 = \text{Annotator Model B.}$

两者互相不可见。

比较四个对象：

Entity Family Agreement,
Obligation Family Agreement,
Hyperedge Support Agreement,
Temporal Slot Agreement.

例如：

EntityF1, ObligationF1,

以及 exact support：

$$\mathbf{1}[\text{supp}_A(e) = \text{supp}_B(e)].$$

只有 disagreement 才调用第三个 strong model adjudicator。

这样 token cost 会比所有 instance 都三模型投票低得多。

Parameter perturbation invariance test

这一项应该成为我们的核心自动质量测试。

AdmitOR 使用 parameter-domain resampling 去检查不同 generated models 的 behavioral agreement；我们可以把同一思想改造成 **semantic-structure invariance test**。这是我们的推演和扩展，而不是 AdmitOR 方法本身。 ³

对于原题 x ，构造：

Numeric perturbation

例如：

$$35 \rightarrow 43, \quad 55 \rightarrow 61.$$

要求：

$$V_S(x') = V_S(x),$$

$$\text{family}(O_S(x')) = \text{family}(O_S(x)).$$

只能 parameter values 变化。

Unit perturbation

gallons $\rightarrow$ liters。

要求：

$$H_S(x') \cong H_S(x).$$

Horizon perturbation

5 days $\rightarrow$ 8 days。

要求 family-level：

$$H_S(x') \cong H_S(x).$$

expanded scalar rows 可以变化，但 family-level graph 不能变化。

Paraphrase perturbation

shipment $\rightarrow$ procurement $\rightarrow$ replenishment request。

要求：

$$V_S$$

identity 不变。

Parameter-exception perturbation

加入：

day 5 maximum = 39

预期：

$$m_{\text{all}}$$

不变；

只出现：

parameter overrides

True-rule augmentation

加入：

final inventory ≥ 15

预期：

$$m_{\text{all}} \rightarrow m_{\text{all}} + 1$$

但：

$$m_c$$

如果是 unary，则不变。

A/A+ 本身就可以成为我们的第一个 **metamorphic test**。

Solver-based feasibility validation

当 benchmark 有 gold formal model 时，我们可以进行比 objective-value comparison 更严格的 validation。

MIPLIB-NL 的优势就在这里：它显式建立 NL、formal model、raw data 和 executable reference solution 之间的连接，并采用 solver-grounded consistency validation。 ¹⁶

第一步是建立：

$$\pi_E : E_F^{\text{gold}} \rightarrow O_S.$$

然后检查：

$$\text{semantic coverage} = \frac{|\{o \in O_S : \exists e_F, \pi_E(e_F) = o\}|}{|O_S|}.$$

但还可以做更强的 **violation witness test**。

对于 obligation o_k ，暂时移除它对应的 gold constraint family，然后求：

$$\max_x \text{Violation}_{o_k}(x)$$

subject to all remaining gold constraints。

如果：

$$\max \text{Violation}_{o_k} > 0,$$

说明它确实代表一个 independently falsifiable restriction。

这个实验恰好可以验证我们提出的“最小 semantic obligation”定义。

注意，如果：

$$\max \text{Violation}_{o_k} = 0,$$

不能直接判定 annotation 错，因为该 business rule 可能被其他 constraints 冗余蕴含；应标记：

semantically explicit but algebraically redundant

而不是删除它。

研究员的小样本审查到底审什么

我们没有专家团队，所以 researcher 不应该试图逐题“重新建一个完美 MILP”。

只审查四个问题：

- 1. 每个 entity 是否能在原文找到 operational referent；
- 2. 每个 obligation 是否有 source evidence；
- 3. 两个可独立违反的规则是否错误合并；
- 4. 只有参数、边界、单位或 temporal offset 差异的规则是否错误拆分。

这样人工工作量会比“专家重建完整 gold model”小一个数量级。

十二个 anchor instances 的选择

建议保留我们此前的 12-instance purposive diagnostic sample：

数据源	数量	选择目标
IndustryOR Easy	2	一个低交互、一个有明显 multi-rule coupling
IndustryOR Hard	2	一个 dense structural rules、一个 temporal/exception-rich
NL4OPT	2	simple LP baseline + relative high-overlap LP
MIPLIB-NL	2	sparse family structure + indexed/temporally coupled structure
LEAN-LLM-OPT	2	moderate structured model + large-scale/multi-index model
OPT-Engine	2	canonical base + constraint-augmented counterpart
总计	12	不用于 statistical inference，只做 metric sanity

这一组合覆盖的 benchmark 结构确实互补：NL4OPT 面向 semantic-to-logical-form LP；MIPLIB-NL 面向 industrial-scale reconstructed MILP；LEAN-LLM-OPT 提供 description+datasets 的 large-scale autoformulation setting；OPT-Engine 则天然带 controllable scaling/constraint augmentation。

抽样表格模板

正式 pilot 建议每题存一行：

字段	内容
dataset	IndustryOR / NL4OPT / MIPLIB-NL / LEAN / OPT-Engine
instance_id	原 benchmark ID
problem_class	inventory / routing / scheduling / etc.
source_text	path/id
external_data	yes/no
gold_model	yes/no
n_S	semantic entity families
m_{all}	all semantic obligations
m_c	coupling obligations
unary ratio	m_{unary} / m_{all}
temporal dependency	yes/no
max decision-effect lag	integer / NA
exception count	threshold/conditional overrides
D_I	numeric
$D_{\cap}$	numeric
J_+	numeric
C_{spec}	numeric
C_{tw}	exact/bounds
C_{hub}	numeric
μ	numeric
LCC	numeric
n_F, m_F	formulation-layer
semantic/formulation divergence	summary
annotator agreement	score
researcher audit	pass/fail
perturbation suite	pass rate
notes	anomalies

Pilot 不应该先看 accuracy correlation


第一阶段首先验证 metric 本身有没有测对东西。

顺序应是：



Mermaid 实验时间线

这里用“阶段”而不是承诺具体耗时：



Pilot 最应该出的几张图

第一张：

$$\text{instances} \times \text{metrics}$$

heatmap.

目标是肉眼判断：

- scheduling/routing 是否出现更高 treewidth；
- star-like resource allocation 是否出现高 hubness；
- modular problems 是否 LCC 较低；
- constraint augmentation 是否只是 m_{all} 上升，还是 coupling topology 真发生变化。

第二张：

$$\log n, \log m \quad \text{vs.} \quad C_{\text{spec}}, C_{\text{tw}}, D_{\square}, J_{+}.$$

如果所谓 normalized coupling 仍几乎只是 size 的函数，就需要重做 normalization。

第三张：

$$\mathbf{C}_S \quad \text{vs.} \quad \mathbf{C}_F.$$

这可能成为论文最有价值的 figure 之一，因为 OptiDSL 和最新 constraint-model work 已经说明 formulation representation 本身会改变 modeling/solver behavior。 2

第四张：

Δ semantic complexity

对 controlled augmentation。

例如 $A \rightarrow A+$ ：

	A	A+	
semantic entities	3	3	
obligation families	6	7	↑
coupling edges	2	2	=
spectral coupling	.683	.683	=
treewidth norm	1.00	1.00	=
decision lag	0	1	↑
exception count	0	1	↑

这张表已经说明了一个非常重要的 methodological point：

“多了几个 constraints” /

⇒ “constrain

而是可能：

$$\text{augmentation} \Rightarrow \begin{cases} \text{obligation burden} \uparrow \\ \text{temporal complexity} \uparrow \\ \text{exception heterogeneity} \uparrow \\ \text{structural coupling} = \text{constant} \end{cases}$$

这实际上比 “给 constraint coupling 找一个 scalar” 更有研究价值。

当前最值得冻结的 SOH-1.1 核心原则因此可以压缩成一句话：

One node per operational entity family; one obligation per independently falsifiable business-rule

也就是说，我们首先确保图的同构性来自问题语义，而不是 annotator 的写法；只有做到这一点，后面的 spectral radius、treewidth、overlap、hubness 等数字才真正有资格被称为 operational-complexity candidates。

1 4 5 17 <https://nl4opt.github.io/>
<https://nl4opt.github.io/>

2 11 <https://arxiv.org/abs/2608.07040>
<https://arxiv.org/abs/2608.07040>

3 <https://arxiv.org/abs/2608.15565>
<https://arxiv.org/abs/2608.15565>

6 <https://arxiv.org/abs/2608.02641>
<https://arxiv.org/abs/2608.02641>

- 7 <https://doi.org/10.48550/arXiv.2601.19924>
<https://doi.org/10.48550/arXiv.2601.19924>
- 8 <https://github.com/ORAgentBench/ORAgentBench>
<https://github.com/ORAgentBench/ORAgentBench>
- 9 <https://arxiv.org/abs/2601.09635>
<https://arxiv.org/abs/2601.09635>
- 10 <https://arxiv.org/abs/2602.10450>
<https://arxiv.org/abs/2602.10450>
- 12 <https://arxiv.org/abs/2608.08127>
<https://arxiv.org/abs/2608.08127>
- 13 <https://github.com/junbolian/AdmitOR>
<https://github.com/junbolian/AdmitOR>
- 14 <https://arxiv.org/abs/2007.14169>
<https://arxiv.org/abs/2007.14169>
- 15 16 <https://github.com/optsuite/MIPLIB-NL>
<https://github.com/optsuite/MIPLIB-NL>